SCH 순천향대학교

ARTIFICIAL INTELLIGENCE CONVERGENCE SOFTWARE
순천향대학교 인공지능 융합 소프트웨어 연구실

Batch Normalization, Layer Normalization, Skip-Connection

발표 |박성진
010 – 9450 – 6778
ppssjj020222@gmail.com
순천향대학교 멀티미디어관

CONTENTS

01 Batch Normalization

02 Layer Normalization

03 Skip-Connection

04 Q&A

01 | Batch Normalization ReLU

- Batch size=5 라고 하고 특정 노드에 “들 " 어간다면

- 전부 양수로 들어간다면..? 전부 음수로 들어간다면..?
- 적절하게 들어가면 좋겠네~ **재배치** 시켜보자!
  - 재배치 하되, 얘네들 순서는 유지시킵시다
- 여기서 잠깐 연습! 평균과 분산

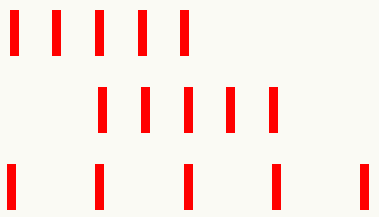

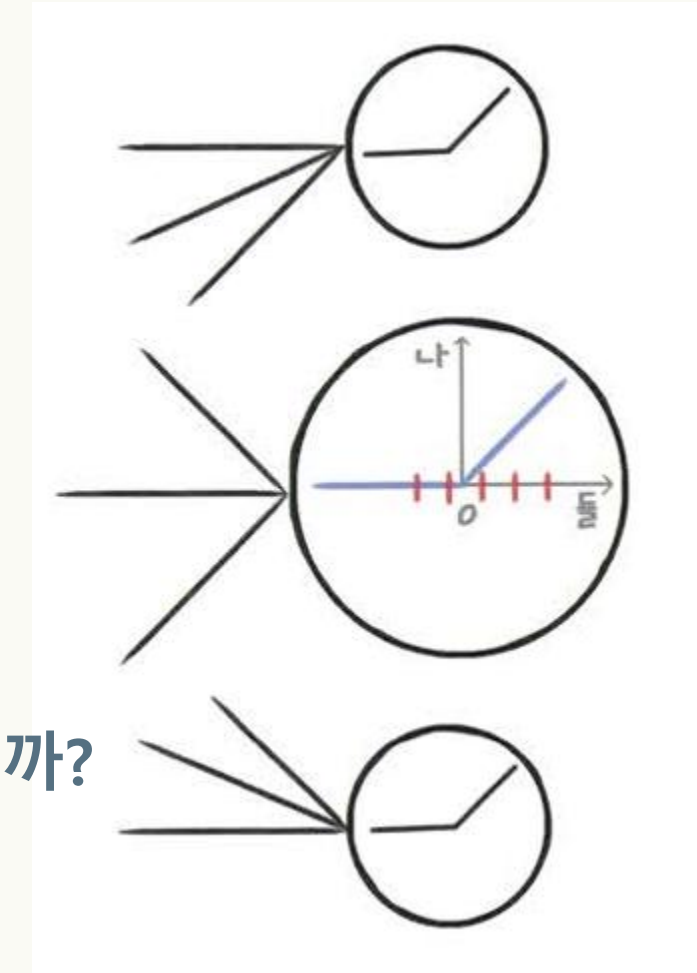

- 그럼 평균 0 분산 1이 되도록 재배치(normalization) 시켜볼까?
  - Sigmoid라면..

01 | Batch Normalization

Sigmoid

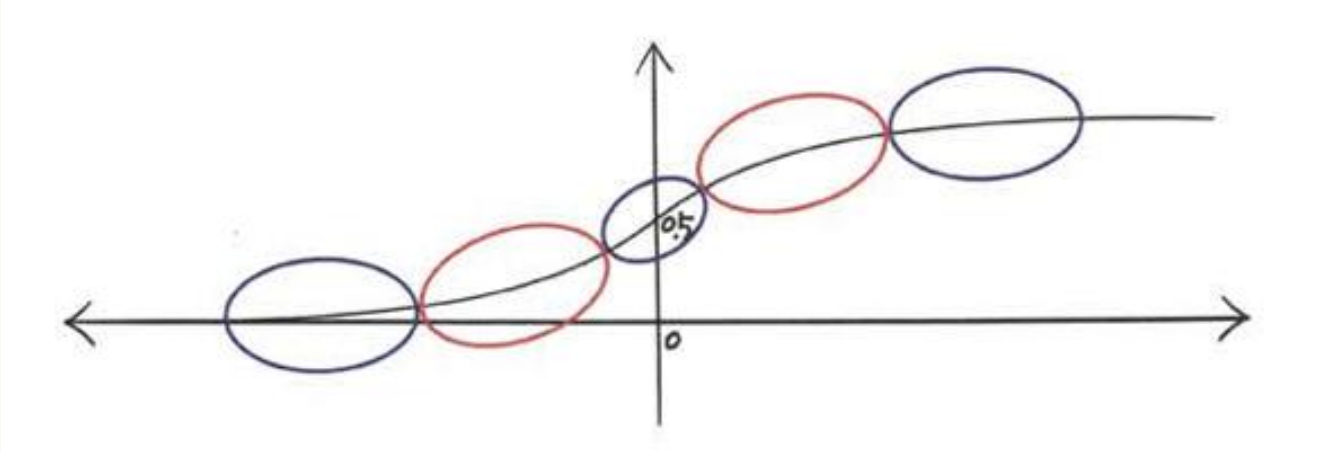

- 그래프 중앙, 외각 부분(파란색) 비선형성이 부족
- 중간 부분(빨간색)은 비성형성은 적당하지만 미분값이 작다

- 따라서, 일부는 중앙에, 일부는 빨간 부분에 들어가야 균형을 맞출수 있다
  - 여기서 평균은 0, 분산 1이 아니다.
  - 또한, ReLU의 경우에도 평균 0, 분산 1로 재배치하는 것이 최적이 아님
  - 활성화 함수에 따라 최적의 재배치 위치를 정확히 알기 어렵다.

01 | Batch Normalization

Normalization

- 그럼, 어디로 재배치시킬지 학습시키자
- 즉, 어디에(평균), 얼만큼 세게 뿌릴지(분산)를 학습시키자!(마치 모래알) how?
- 먼저 Normalization(정규화) 진행

X: 각 입력값

$\bar{X}$: 배치 5개 값의 평균

σ_X: 배치 5개 값의 표준편차

$$\frac{X-\bar{X}}{\sigma_X}$$

입력값: 1,2,3,4,5
평균: 3

1. 각 입력값에서 평균을 뺍니다 $X-\bar{X}$
2. 평균이 0으로 이동되었습니다.
3. 1의 결과를 표준편차로 나눕니다.
4. 분산과 표준편차가 1이 됩니다.

평균 0

분산 1

01 | Batch Normalization

Normalization

원래 데이터 $1, 2, 3, 4, 5$

평균 $\bar{X} = 3$

평균을 빼면 $-2, -1, 0, 1, 2$

분산을 계산하면
$$\sigma_X^2 = \frac{(-2)^2 + (-1)^2 + 0^2 + 1^2 + 2^2}{5} = \frac{4+1+0+1+4}{5} = \frac{10}{5} = 2$$

표준편차는 $\sigma_X = \sqrt{2}$

이제 각값을 표준편차로 나누면 $\frac{-2}{\sqrt{2}}, \frac{-1}{\sqrt{2}}, 0, \frac{1}{\sqrt{2}}, \frac{2}{\sqrt{2}}$

즉 $-\sqrt{2}, -\frac{1}{\sqrt{2}}, 0, \frac{1}{\sqrt{2}}, \sqrt{2}$

새로운 값들의 평균은 여전히 0-> 분산은 그냥 제곱 평균
$$\frac{1}{5}\left[\left(-\sqrt{2}\right)^2 + \left(-\frac{1}{\sqrt{2}}\right)^2 + 0^2 + \left(\frac{1}{\sqrt{2}}\right)^2 + \left(\sqrt{2}\right)^2\right]$$

따라서
$$\frac{1}{5}\left(2 + \frac{1}{2} + 0 + \frac{1}{2} + 2\right) = \frac{1}{5}(5) = 1$$

분산 = 1

표준편차는 $\sqrt{1} = 1$

01 | Batch Normalization 학습

- Normalization 된 값을 재배치 단계
- 학습 파라미터로 조절
  - a: 얼마나 스케일할지(분산)
  - b: 어디로 이동시킬지(평균)

- 새 파라미터에 대해서 미분 가능성 확인
  - a, b 미분 가능
  - 역전파 지장 없음(X 미분 가능)

$$a\left(\frac{X-\bar{X}}{\sigma_X}\right)+b$$

01 | Batch Normalization 학습

$$a\left(\frac{X-\bar{X}}{\sigma_X}\right)+b$$

- 어디에(평균), 얼마나 넓게(분포) 뿌릴지를 학습한다는 것은 어떠한 의미..?
- 각 노드에 대해서 **비선형성**과 **소실 문제** 해결 사이의 균형을 학습
  - 입력값들의 전반적인 **위치와 분포**에 따라 **비선형성과 기울기 소실 문제**의 발생 가능성이 달라짐

- 원하는 층에 적용 가능
- 각 노드마다 평균 및 분산 계산, 두개의 파라미터 추가
- 각 노드 앞에 **입력값을 재배치**하는 **배치 정규화 모듈**이 존재한다고 해석 가능

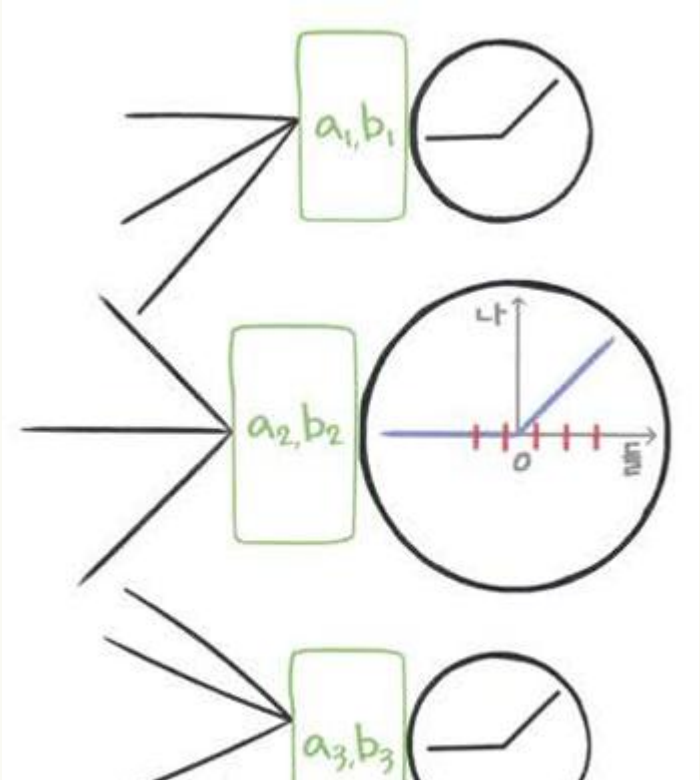

해당 node에 대해
Nonelinearity를 얼마나 살리면서
Vanishing gradient를 얼마나 해결할지, AI가 알아내는 것!

01 | Batch Normalization 학습

- Training 때와 Test때 다르게 동작함 why?
  - Training때는 배치 학습으로 여러 개의 input값을 입력 -> 평균, 분산 계산
  - Test때는 하나의 input값을 입력하게 되는 상황도 있음

$$a\left(\frac{X-\bar{X}}{\sigma_X}\right)+b$$

- Training때 구한 값(평균, 분산)들을 moving average로 사용(Like Adam)

- 또, Batch Size = 2(엄청 작게)로 두고 Batch Normalization을 훈련??
  - BN은 현재 batch를 보고 "이 층의 값들이 대충 어디에 있고 얼마나 퍼져 있나"를 추정(현재 데이터 분포를 잘 대표)
  - 즉, Batch size에 따라 영향을 받는다는 단점이 있다..!

- sigmoid
  - Values = 해당 레이어의 활성값 Batch = 배치 사이즈
  - Z축 = 그 값이 얼마나 나왔는지

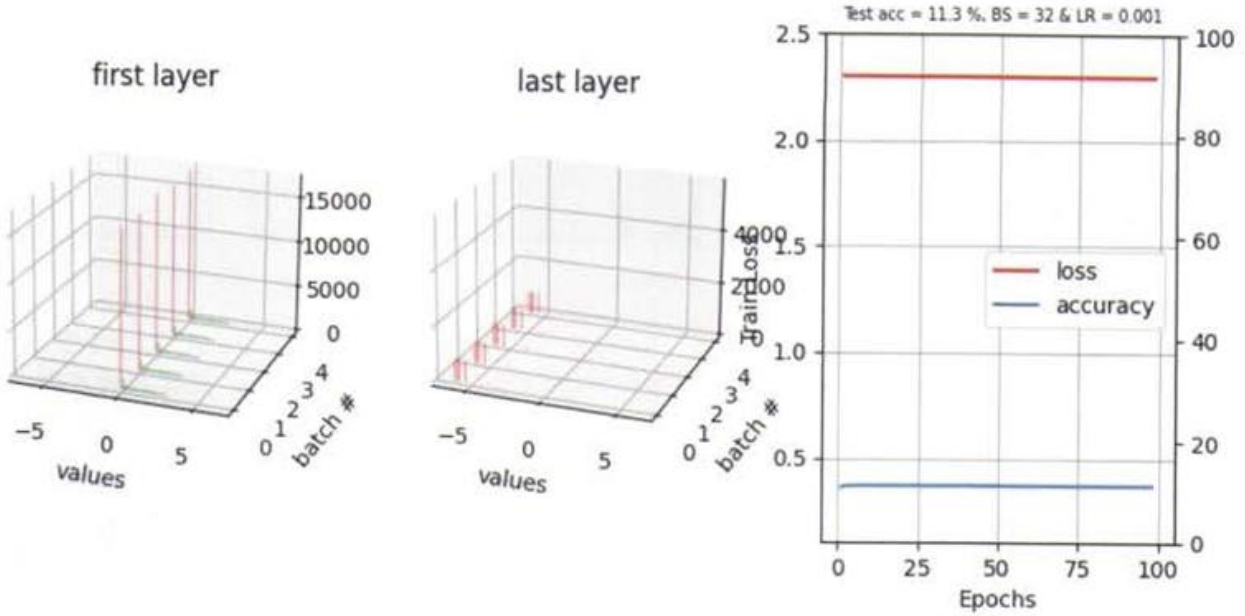

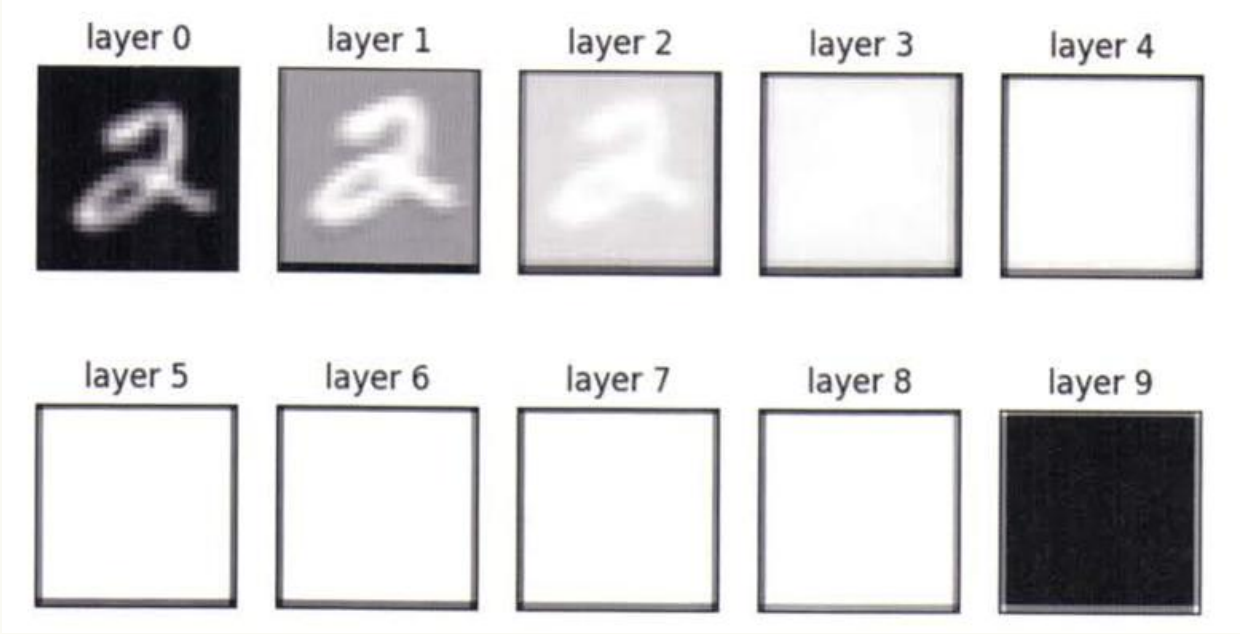

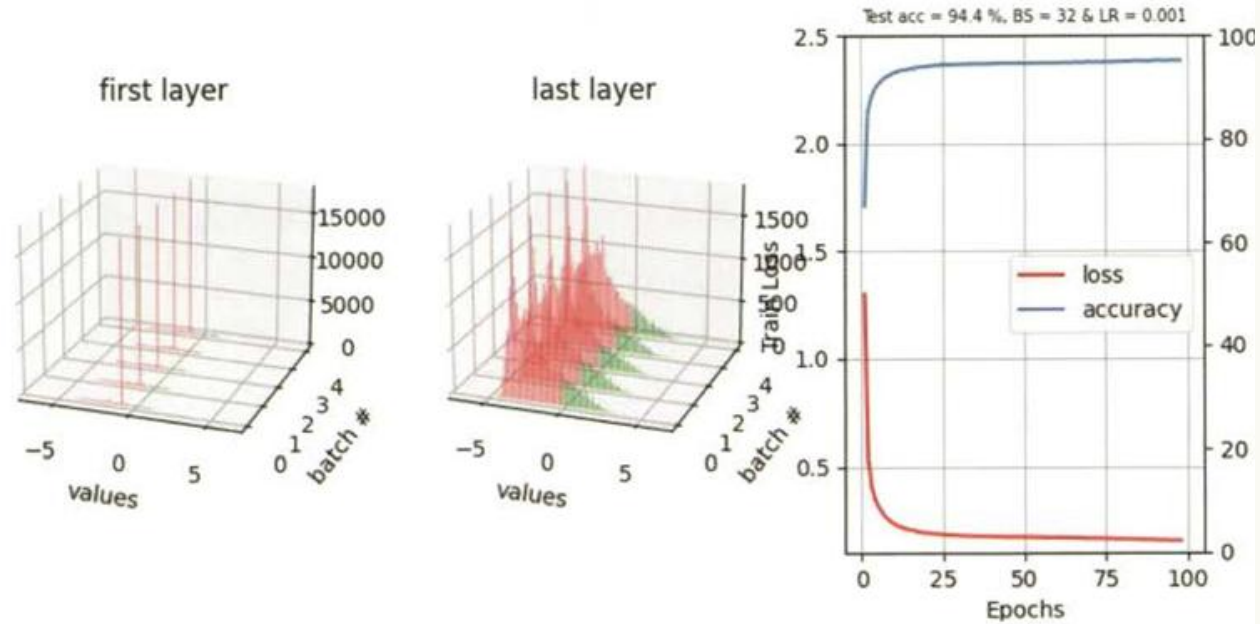

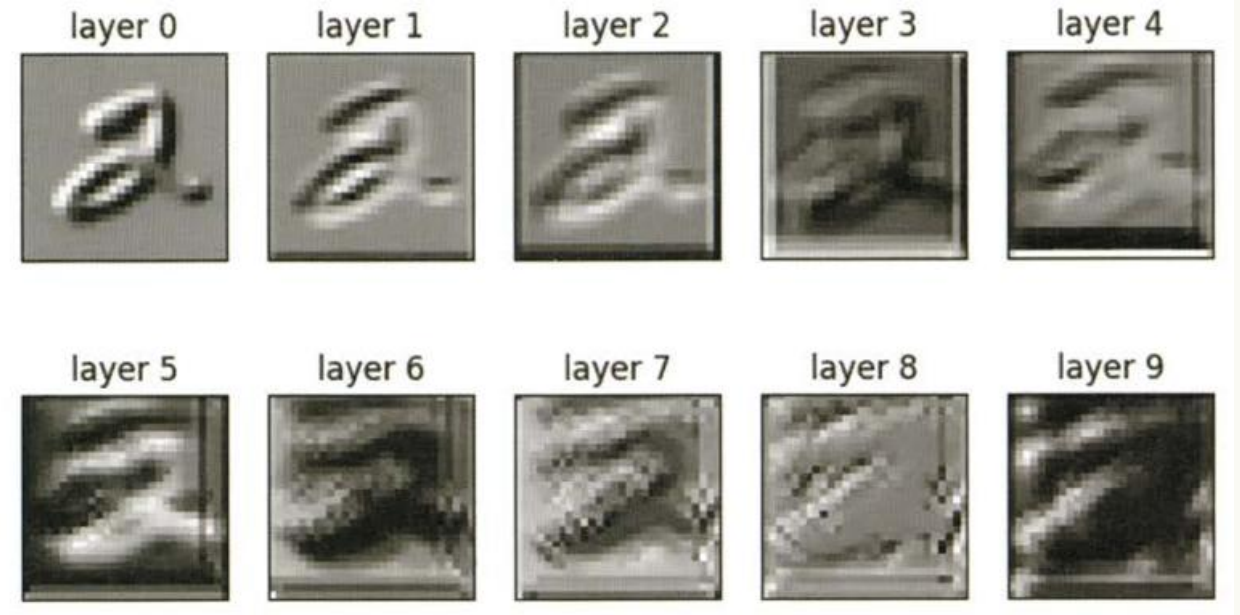

02 | Layer Normalization 학습

- **Layer normalization은?**

$$a\left(\frac{X-\bar{X}}{\sigma_X}\right)+b$$

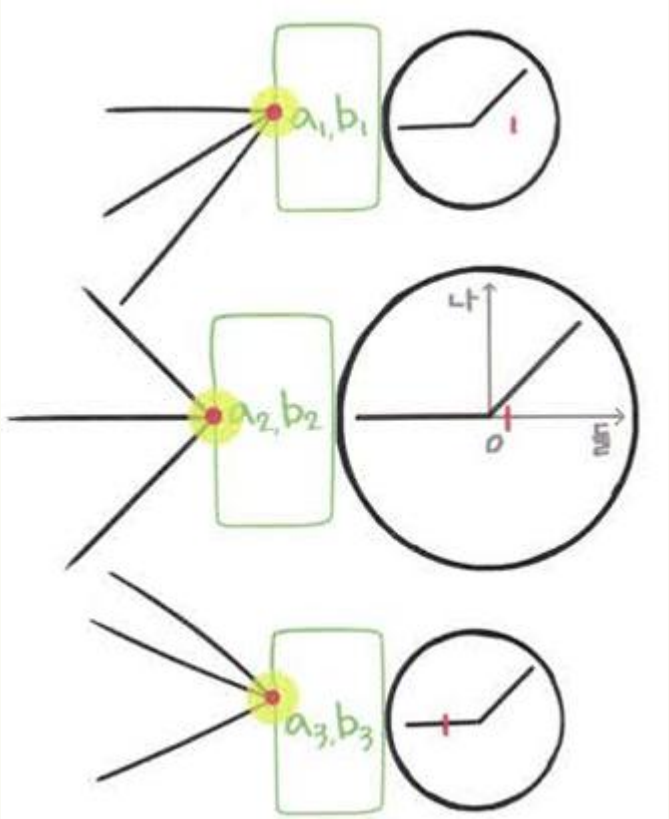

- 배치 정규화의 한계(배치 사이즈 제약)
- 레이어 정규화는 BatchSize에 영향을 받지 않음
- 레이어에 들어가는 입력값들을 샘플로 사용해 평균과 분산 계산

02 | Layer Normalization 학습

- **Layer normalization은?**
  - **세 노드에 들어가는 입력값 세 개에 대해, 평균 분산 구함**
  - **"뭘로 평균, 분산 구할 거냐" 만 다르고 BN 과 마찬가지, 노드당 두개의 파라미터 추가!**
- LN은 Training때와 Test때 동일한 방식으로 계산함!
  - BN과 달리 Batch size에 영향을 받지 않는다는 장점!
- 이미지 데이터는 BM을 자연어 처리 쪽에는 LN을 주로 사용
  - <pad>토큰 때문

02 | Layer Normalization 학습

- 파란 애들을 샘플로 본다는 뜻! (샘플 평균, 샘플 분산을 얘네들로 구해)

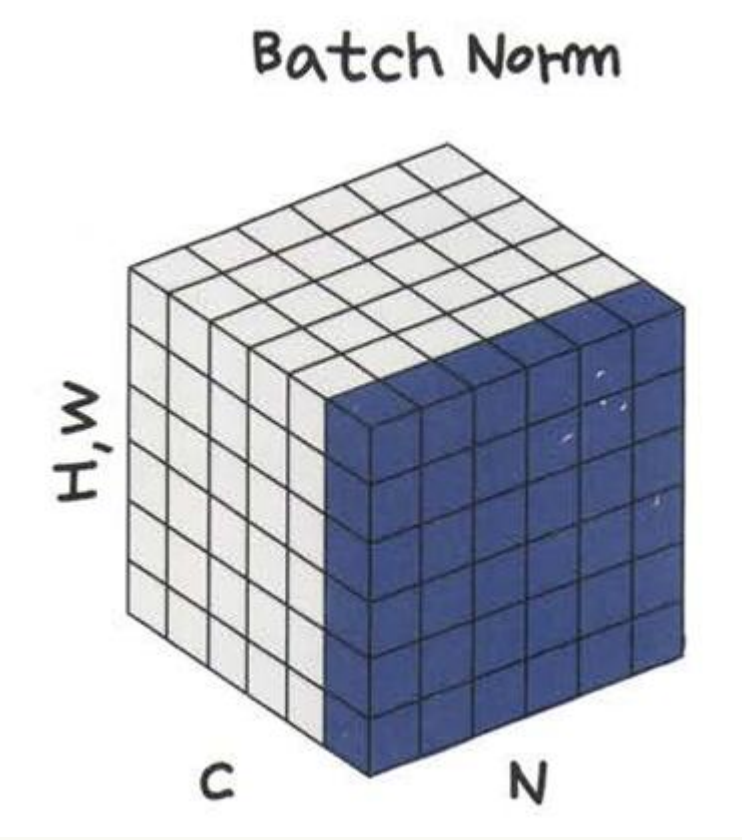

- 같은 채널 내의 모든 픽셀들에 대해서 계산

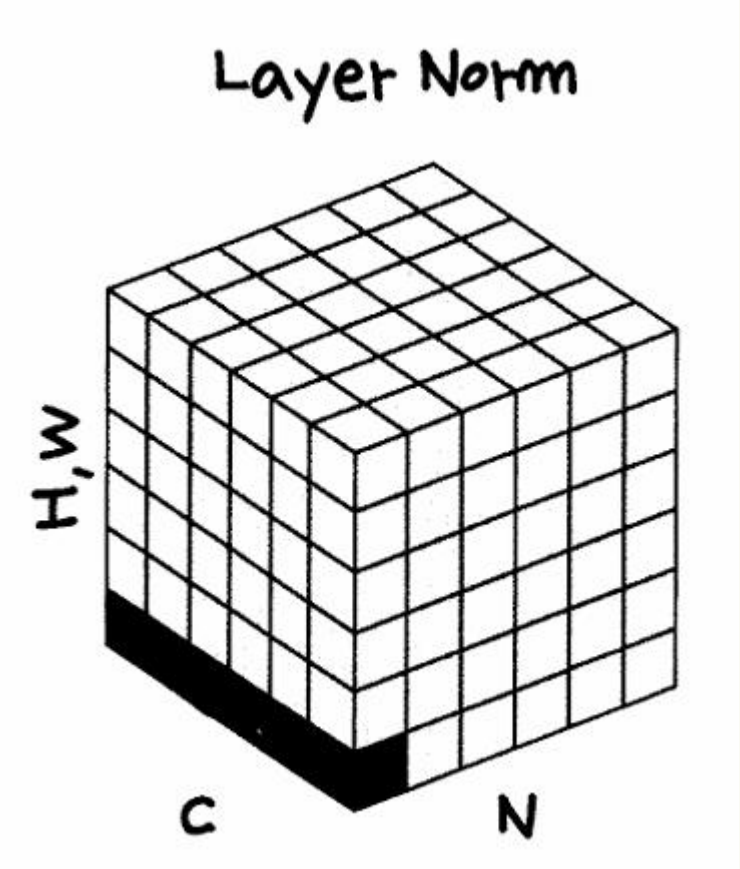

- 각 데이터의 각 픽셀 위치에서 모든 채널에 대해서 계산

02 | Layer Normalization 학습

- ReLU로 바꾸자
- Batch Normalization
  (어디에 뿌릴지, 얼만큼 세게 뿌릴지를 학습 -> non-linearity 살리면서 vanishing 해결)

- Layer Normalization
  (Batch Normalization의 한계 극복)

03 | Skip-Connection 학습

- Loss landscape이 꼬불해지는 문제?
- BN, ReLU 콤비로 분면 vanishing gradient 해결 했는데…
- 그래도 너무 깊으면 학습이 안되더라(underfitting)

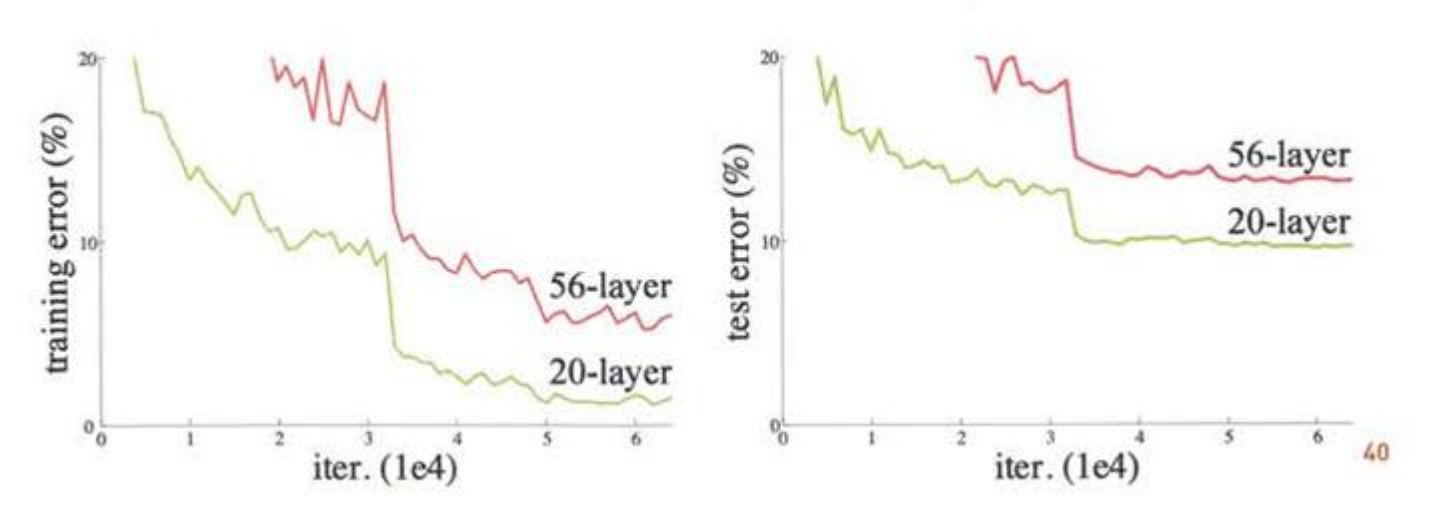

03 | Skip-Connection 학습

- 깊게 만들수록 loss 모양이 이상해진다!
- ResNet의 skip-connection 이 대표적인 해결 방안 중 하나

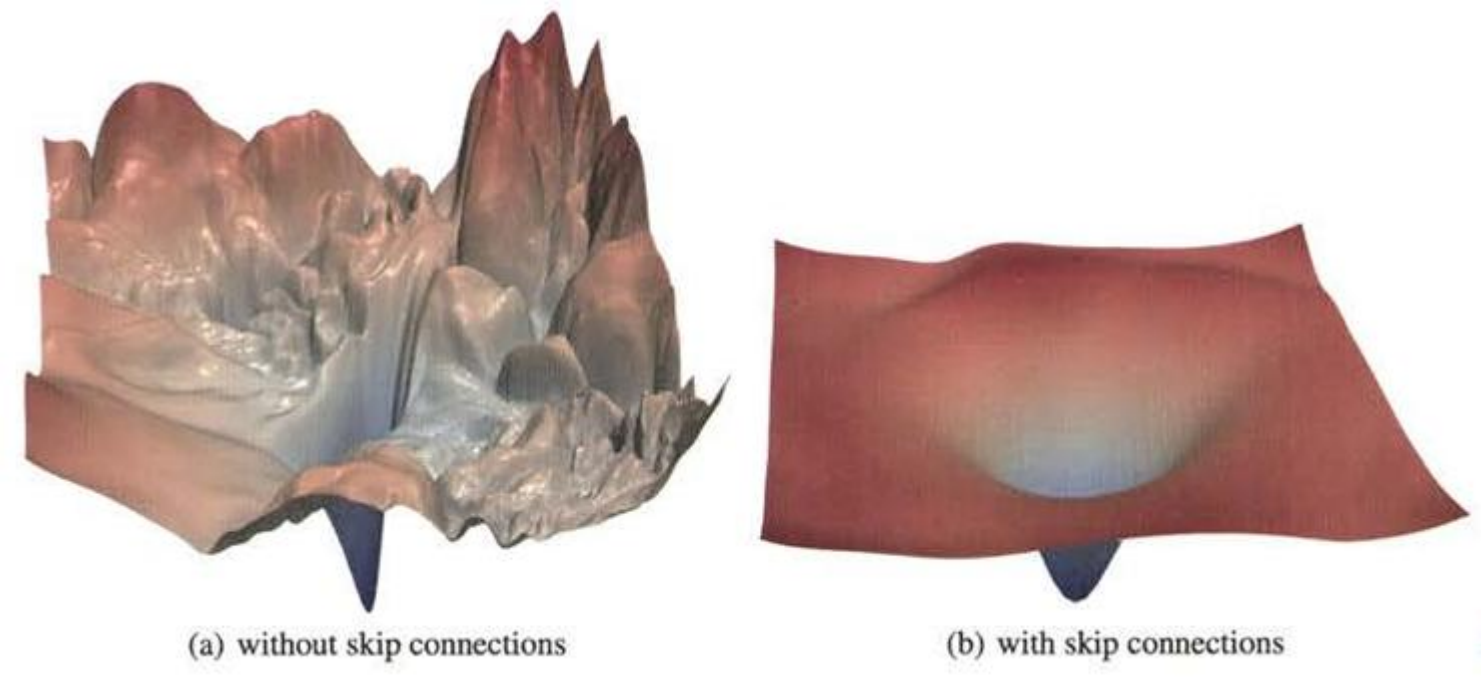

03 | Skip-Connection 학습

- 블록을 통과하기 전의 값을 블록 통과 후에 더하는 간단한 기법
- 블록 : 2~3개의 인공 신경망 층을 하나로 묶는 것을 의미
- 블록의 출력이 f(x)가 아닌 x + f(x)

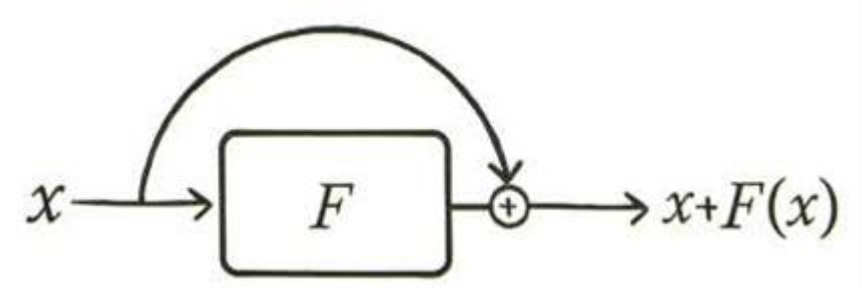

- F(x)는 입력과 출력의 차이(잔차)만을 학습하면 되므로, 학습이 쉬워짐
  - 잔차학습, 최초 적용 CNN모델 : ResNet

Batch Normalization, Layer Normalization, Skip-Connection

감사합니다