순천향대학교

ARTIFICIAL INTELLIGENCE CONVERGENCE SOFTWARE
순천향대학교 인공지능 융합 소프트웨어 연구실

Super-Resolution
SRCNN, VDSR, SRGAN

발표 |박성진
010 – 9450 – 6778
ppssjj020222@gmail.com
순천향대학교 멀티미디어관

CONTENTS

01 Super-Resolution

02 SRCNN

03 VDSR - 심층리뷰

04 SRGAN

01 | Super-Resolution

HR(고해상도) vs LR(저해상도)

- 픽셀 수, 정보량
- 고주파 정보(픽셀 값 급변화), 저주파 정보(픽셀 값 저변화)

- 해당 이미지에 얼마나 많은 시각적 정보와 세부 구조를 담고 있느냐의 차이

01 | Super-Resolution

스케일

- Scale: 이미지를 몇 배로 복원할 것인지를 나타냄
- X2, x3, x4
- 가로, 세로를 각각 두배, 세배로 확대하는 것
- 만약 원본 이미지가 10x10이라면? → X4 확대 했을 경우
- 총 픽셀 수는 100x100x16
  - 스케일이 커질 수록 입력 이미지에 있는 정보가 부족해짐.

그림 그리기

01 | Super-Resolution

SISR

- SISR(Single Image Super-Resolution) : 단 한장의 저해상도 이미지로부터 한 장의 고해상도 이미지를 복원하는 문제.
- 여러장의 저해상도 이미지로부터 변환하는 것보다 단 한장의 저해상도 이미지로 복원하는 것이 어려움.
- Ill-posed problem : 정답이 명확하게 하나로 딱 정해지지 않은 문제

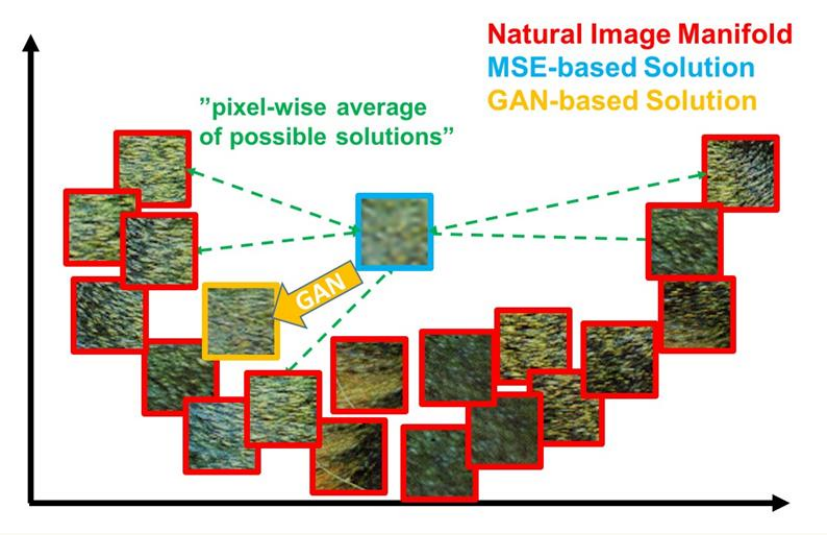

01 | Super-Resolution

전통 – Bicubic interpolation

- 딥러닝 기반 SR 이전에는 이미지를 확대할 때 보간법이 주로 사용됨
  - 대표 : Bucubic interpolation

- **Bicubic: 주변 픽셀 값을 참고해 새로운 픽셀 값을 계산하는 방식**
  - **기존 픽셀 사이의 빈공간을 주변 값을 이용해 부드럽게 메우는 방법**

- 한계
  - 경계가 흐려짐 --> 부드럽게 처리되어 blur가 생김
  - **텍스처 복원이 어려움 → 고주파 정보 소실**

- 그림 그리기

01 | Super-Resolution 논문

- **SRCNN**

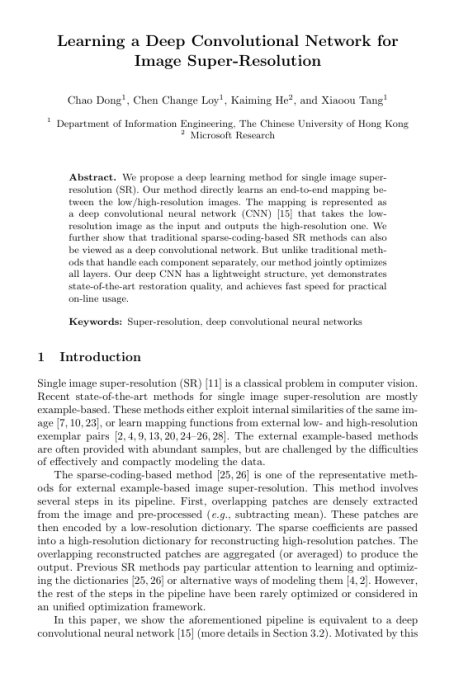

Learning a Deep Convolutional Network for Image Super-Resolution

Chao Dong[1], Chen Change Loy[1], Kaiming He[2], and Xiaoou Tang[1]

[1] Department of Information Engineering, The Chinese University of Hong Kong
[2] Microsoft Research

Abstract. We propose a deep learning method for single image super-resolution (SR). Our method directly learns an end-to-end mapping between the low/high-resolution images. The mapping is represented as a deep convolutional neural network (CNN) [15] that takes the low-resolution image as the input and outputs the high-resolution one. We further show that traditional sparse-coding-based SR methods can also be viewed as a deep convolutional network. But unlike traditional methods that handle each component separately, our method jointly optimizes all layers. Our deep CNN has a lightweight structure, yet demonstrates state-of-the-art restoration quality, and achieves fast speed for practical on-line usage.

Keywords: Super-resolution, deep convolutional neural networks

1 Introduction

Single image super-resolution (SR) [11] is a classical problem in computer vision. Recent state-of-the-art methods for single image super-resolution are mostly example-based. These methods either exploit internal similarities of the same image [7, 10, 23], or learn mapping functions from external low- and high-resolution exemplar pairs [2, 4, 9, 13, 20, 24–26, 28]. The external example-based methods are often provided with abundant samples, but are challenged by the difficulties of effectively and compactly modeling the data.

The sparse-coding-based method [25, 26] is one of the representative methods for external example-based image super-resolution. This method involves several steps in its pipeline. First, overlapping patches are densely extracted from the image and pre-processed (*e.g.*, subtracting mean). These patches are then encoded by a low-resolution dictionary. The sparse coefficients are passed into a high-resolution dictionary for reconstructing high-resolution patches. The overlapping reconstructed patches are aggregated (or averaged) to produce the output. Previous SR methods pay particular attention to learning and optimizing the dictionaries [25, 26] or alternative ways of modeling them [4, 2]. However, the rest of the steps in the pipeline have been rarely optimized or considered in an unified optimization framework.

In this paper, we show the aforementioned pipeline is equivalent to a deep convolutional neural network [15] (more details in Section 3.2). Motivated by this

- **VDSR - 심층**

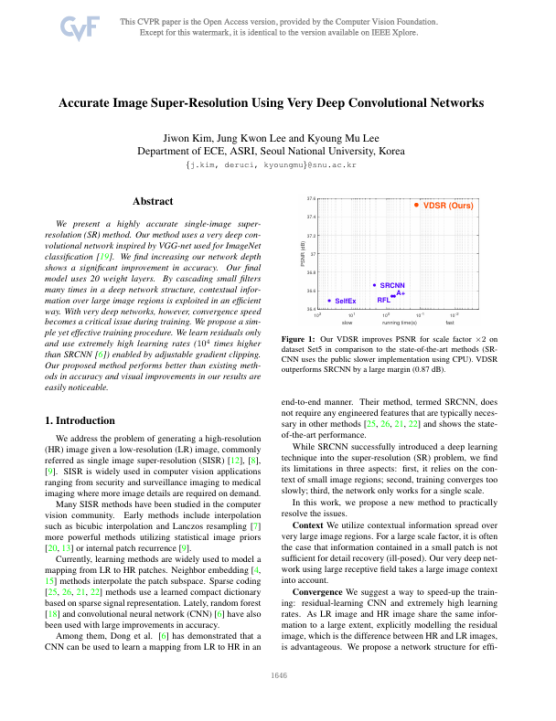

This CVPR paper is the Open Access version, provided by the Computer Vision Foundation.
Except for this watermark, it is identical to the version available on IEEE Xplore.

Accurate Image Super-Resolution Using Very Deep Convolutional Networks

Jiwon Kim, Jung Kwon Lee and Kyoung Mu Lee
Department of ECE, ASRI, Seoul National University, Korea
{j.kim, deruci, kyoungmu}@snu.ac.kr

Abstract

We present a highly accurate single-image super-resolution (SR) method. Our method uses a very deep convolutional network inspired by VGG-net used for ImageNet classification [19]. We find increasing our network depth shows a significant improvement in accuracy. Our final model uses 20 weight layers. By cascading small filters many times in a deep network structure, contextual information over large image regions is exploited in an efficient way. With very deep networks, however, convergence speed becomes a critical issue during training. We propose a simple yet effective training procedure. We learn residuals only and use extremely high learning rates (10^4 times higher than SRCNN [6]) enabled by adjustable gradient clipping. Our proposed method performs better than existing methods in accuracy and visual improvements in our results are easily noticeable.

Figure 1: Our VDSR improves PSNR for scale factor ×2 on dataset Set5 in comparison to the state-of-the-art methods (SR-CNN uses the public slower implementation using CPU). VDSR outperforms SRCNN by a large margin (0.87 dB).

1. Introduction

We address the problem of generating a high-resolution (HR) image given a low-resolution (LR) image, commonly referred as single image super-resolution (SISR) [12], [8], [9]. SISR is widely used in computer vision applications ranging from security and surveillance imaging to medical imaging where more image details are required on demand.

Many SISR methods have been studied in the computer vision community. Early methods include interpolation such as bicubic interpolation and Lanczos resampling [7] more powerful methods utilizing statistical image priors [20, 13] or internal patch recurrence [9].

Currently, learning methods are widely used to model a mapping from LR to HR patches. Neighbor embedding [4, 15] methods interpolate the patch subspace. Sparse coding [25, 26, 21, 22] methods use a learned compact dictionary based on sparse signal representation. Lately, random forest [18] and convolutional neural network (CNN) [6] have also been used with large improvements in accuracy.

Among them, Dong et al. [6] has demonstrated that a CNN can be used to learn a mapping from LR to HR in an end-to-end manner. Their method, termed SRCNN, does not require any engineered features that are typically necessary in other methods [25, 26, 21, 22] and shows the state-of-the-art performance.

While SRCNN successfully introduced a deep learning technique into the super-resolution (SR) problem, we find its limitations in three aspects: first, it relies on the context of small image regions; second, training converges too slowly; third, the network only works for a single scale.

In this work, we propose a new method to practically resolve the issues.

Context We utilize contextual information spread over very large image regions. For a large scale factor, it is often the case that information contained in a small patch is not sufficient for detail recovery (ill-posed). Our very deep network using large receptive field takes a large image context into account.

Convergence We suggest a way to speed-up the training: residual-learning CNN and extremely high learning rates. As LR image and HR image share the same information to a large extent, explicitly modelling the residual image, which is the difference between HR and LR images, is advantageous. We propose a network structure for effi-

- **SRGAN**

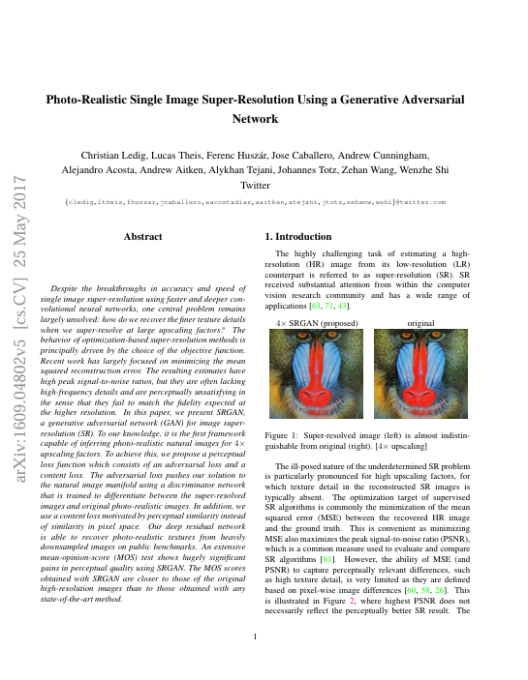

arXiv:1609.04802v5 [cs.CV] 25 May 2017

Photo-Realistic Single Image Super-Resolution Using a Generative Adversarial Network

Christian Ledig, Lucas Theis, Ferenc Huszár, Jose Caballero, Andrew Cunningham, Alejandro Acosta, Andrew Aitken, Alykhan Tejani, Johannes Totz, Zehan Wang, Wenzhe Shi
Twitter
{cledig,ltheis,fhuszar,jcaballero,aacostadiaz,aaitken,atejani,jtotz,zehanw,wshi}@twitter.com

Abstract

Despite the breakthroughs in accuracy and speed of single image super-resolution using faster and deeper convolutional neural networks, one central problem remains largely unsolved: how do we recover the finer texture details when we super-resolve at large upscaling factors? The behavior of optimization-based super-resolution methods is principally driven by the choice of the objective function. Recent work has largely focused on minimizing the mean squared reconstruction error. The resulting estimates have high peak signal-to-noise ratios, but they are often lacking high-frequency details and are perceptually unsatisfying in the sense that they fail to match the fidelity expected at the higher resolution. In this paper, we present SRGAN, a generative adversarial network (GAN) for image super-resolution (SR). To our knowledge, it is the first framework capable of inferring photo-realistic natural images for 4× upscaling factors. To achieve this, we propose a perceptual loss function which consists of an adversarial loss and a content loss. The adversarial loss pushes our solution to the natural image manifold using a discriminator network that is trained to differentiate between the super-resolved images and original photo-realistic images. In addition, we use a content loss motivated by perceptual similarity instead of similarity in pixel space. Our deep residual network is able to recover photo-realistic textures from heavily downsampled images on public benchmarks. An extensive mean-opinion-score (MOS) test shows hugely significant gains in perceptual quality using SRGAN. The MOS scores obtained with SRGAN are closer to those of the original high-resolution images than to those obtained with any state-of-the-art method.

1. Introduction

The highly challenging task of estimating a high-resolution (HR) image from its low-resolution (LR) counterpart is referred to as super-resolution (SR). SR received substantial attention from within the computer vision research community and has a wide range of applications [63, 71, 43].

4× SRGAN (proposed) original

Figure 1: Super-resolved image (left) is almost indistinguishable from original (right). [4× upscaling]

The ill-posed nature of the underdetermined SR problem is particularly pronounced for high upscaling factors, for which texture detail in the reconstructed SR images is typically absent. The optimization target of supervised SR algorithms is commonly the minimization of the mean squared error (MSE) between the recovered HR image and the ground truth. This is convenient as minimizing MSE also maximizes the peak signal-to-noise ratio (PSNR), which is a common measure used to evaluate and compare SR algorithms [61]. However, the ability of MSE (and PSNR) to capture perceptually relevant differences, such as high texture detail, is very limited as they are defined based on pixel-wise image differences [60, 58, 26]. This is illustrated in Figure 2, where highest PSNR does not necessarily reflect the perceptually better SR result. The

01 | SRCNN 간단 설명

- SRCNN: 전통적인 초해상도 파이프 라인을 하나의 CNN으로 통합하여 end-to-end 학습이 가능하게 만든 초기 대표 모델(2014)

- 핵심 키워드: SISR, bicubic upsampling, 3-layer CNN …

Learning a Deep Convolutional Network for Image Super-Resolution

Chao Dong[1], Chen Change Loy[1], Kaiming He[2], and Xiaoou Tang[1]

[1] Department of Information Engineering, The Chinese University of Hong Kong
[2] Microsoft Research

Abstract. We propose a deep learning method for single image super-resolution (SR). Our method directly learns an end-to-end mapping between the low/high-resolution images. The mapping is represented as a deep convolutional neural network (CNN) [15] that takes the low-resolution image as the input and outputs the high-resolution one. We further show that traditional sparse-coding-based SR methods can also be viewed as a deep convolutional network. But unlike traditional methods that handle each component separately, our method jointly optimizes all layers. Our deep CNN has a lightweight structure, yet demonstrates state-of-the-art restoration quality, and achieves fast speed for practical on-line usage.

Keywords: Super-resolution, deep convolutional neural networks

1 Introduction

Single image super-resolution (SR) [11] is a classical problem in computer vision. Recent state-of-the-art methods for single image super-resolution are mostly example-based. These methods either exploit internal similarities of the same image [7, 10, 23], or learn mapping functions from external low- and high-resolution exemplar pairs [2, 4, 9, 13, 20, 24–26, 28]. The external example-based methods are often provided with abundant samples, but are challenged by the difficulties of effectively and compactly modeling the data.

The sparse-coding-based method [25, 26] is one of the representative methods for external example-based image super-resolution. This method involves several steps in its pipeline. First, overlapping patches are densely extracted from the image and pre-processed (*e.g.*, subtracting mean). These patches are then encoded by a low-resolution dictionary. The sparse coefficients are passed into a high-resolution dictionary for reconstructing high-resolution patches. The overlapping reconstructed patches are aggregated (or averaged) to produce the output. Previous SR methods pay particular attention to learning and optimizing the dictionaries [25, 26] or alternative ways of modeling them [4, 2]. However, the rest of the steps in the pipeline have been rarely optimized or considered in an unified optimization framework.

In this paper, we show the aforementioned pipeline is equivalent to a deep convolutional neural network [15] (more details in Section 3.2). Motivated by this

01 | SRCNN 개요

- 과거 초해상도 방법들은 patch extraction, sparse conding reconstruction, aggregation 등 여러 단계를 분리하여 처리

- 각 단계를 개별적으로 설계 → 최적화의 한계

- SRCNN은 기존 초해상도 방법의 파이프 라인을 CNN으로 해석하여 이미지를 복원하는 매핑을 학습

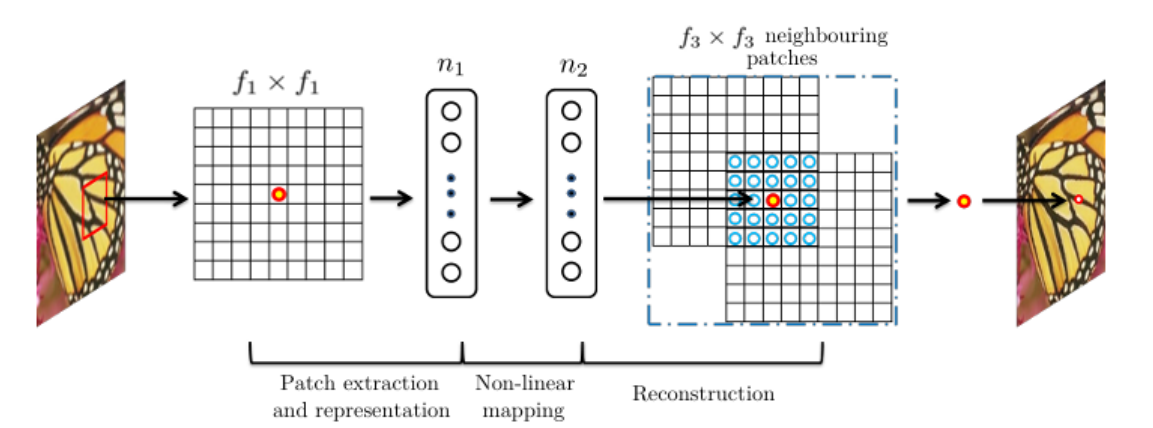

01 | SRCNN

제안 배경

- 복원 중 저해상도 이미지에 이미 많은 정보(고주파)가 손실 → 복원의 어려움
- 기존 방법(patch- based)
- 각 단계 별로 동릭적으로 설계 → 전체 파이프라인을 end-to-end로 최적화하기 어려움
- SRCNN은 이러한 한계를 해겨랗기 위해 기존 초해상도 과정을 CNN 관점으로 재해석하고 이를 하나의 학습 가능한 네트워크로 통합

01 | SRCNN

핵심 구조

- 입력 전처리, 3개의 convolution layer

- 입력 전처리: 저해상도 이미지를 bicubic interpolatioin으로 원하는 출력 크기까지 확대
  - 해당 이미지를 Y
  - SRCNN은 작은 LR이미지를 바로 크게 만드는 것이 아닌, 이미 크기는 맞지만 디테일이 부족한 bicubic interpolation 이미지 Y를 입력으로 받아 이를 더 선명한 이미지로 복원

- 그림 그리기

01 | SRCNN

핵심 구조

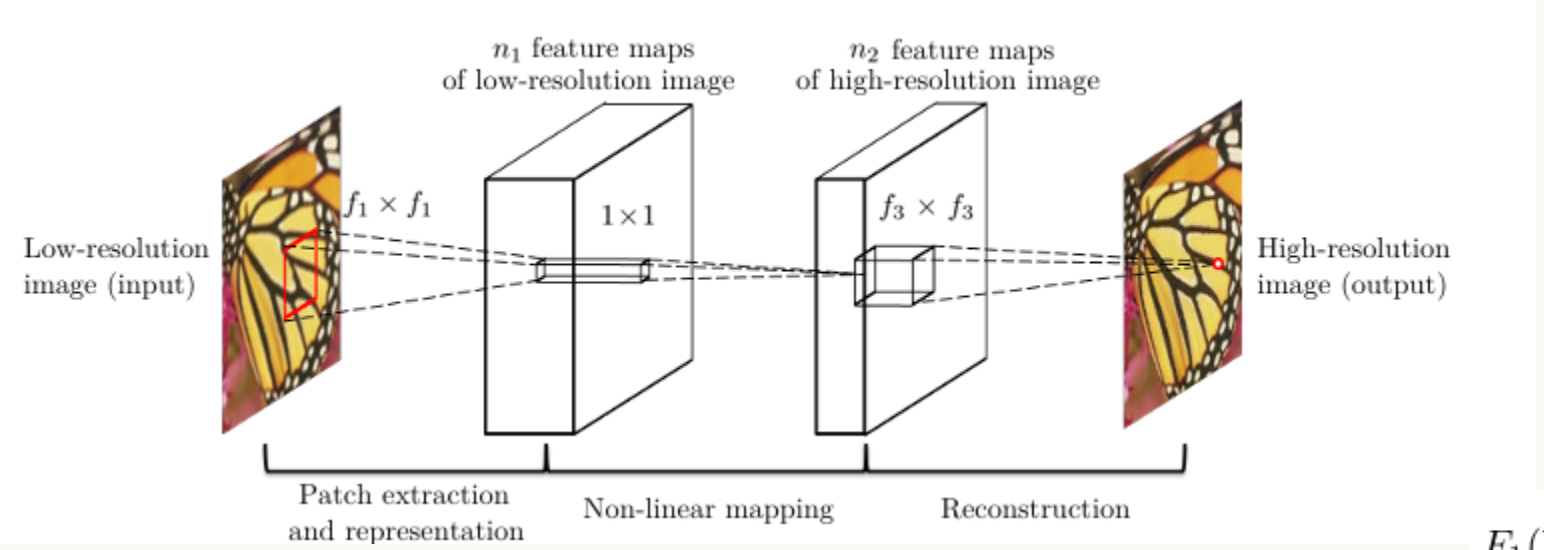

$$F_1(\mathbf{Y}) = \max(0, W_1 * \mathbf{Y} + B_1)$$

- 1층: 이미지에서 중요한 부분을 먼저 찾음(특징 추출 → 커널 크기 9x9, 필터 수 64개)

- 첫번째 conv는 입력 이미지에서 선, 경계, 모서리, 밝기 변화 같은 기본적인 특징을 뽑아내는 단계
- 이미지를 바로 복원하는 것이 아닌 어디에 윤곽, 패턴이 있는 지 살펴보는 과정

01 | SRCNN

핵심 구조

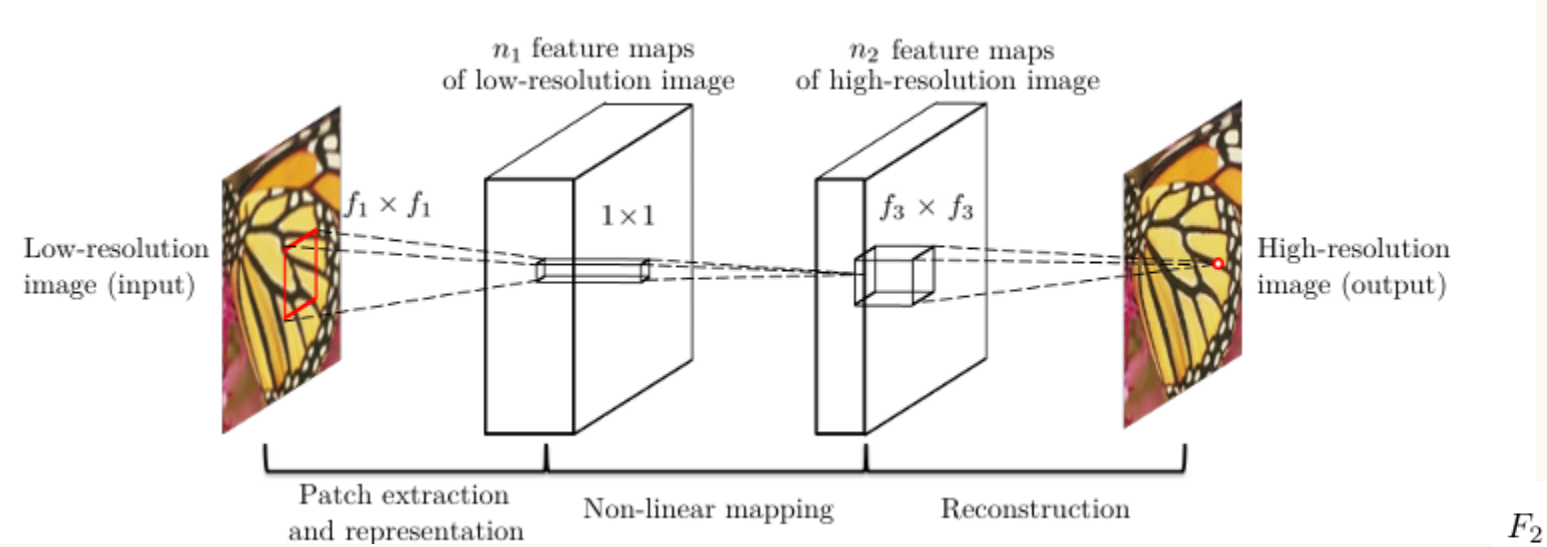

$$F_2(\mathbf{Y}) = \max(0, W_2 * F_1(\mathbf{Y}) + B_2).$$

- 2층: 복원에 더 유리한 형태로 특징을 가공(특징 변환, ReLU, 커널 크기 1x1, 필터 수 32개)

- 두 번째 conv는 첫번 째 층에서 찾은 특징들을 그대로 쓴느 것이 아닌, 고해상도 이미지로 복원하기 좋게 다시 정리하고 변환하는 단계
- 여러 정보들을 조합하여 어떻게 복원하면 좋을지, 중요도 판단

01 | SRCNN

핵심 구조

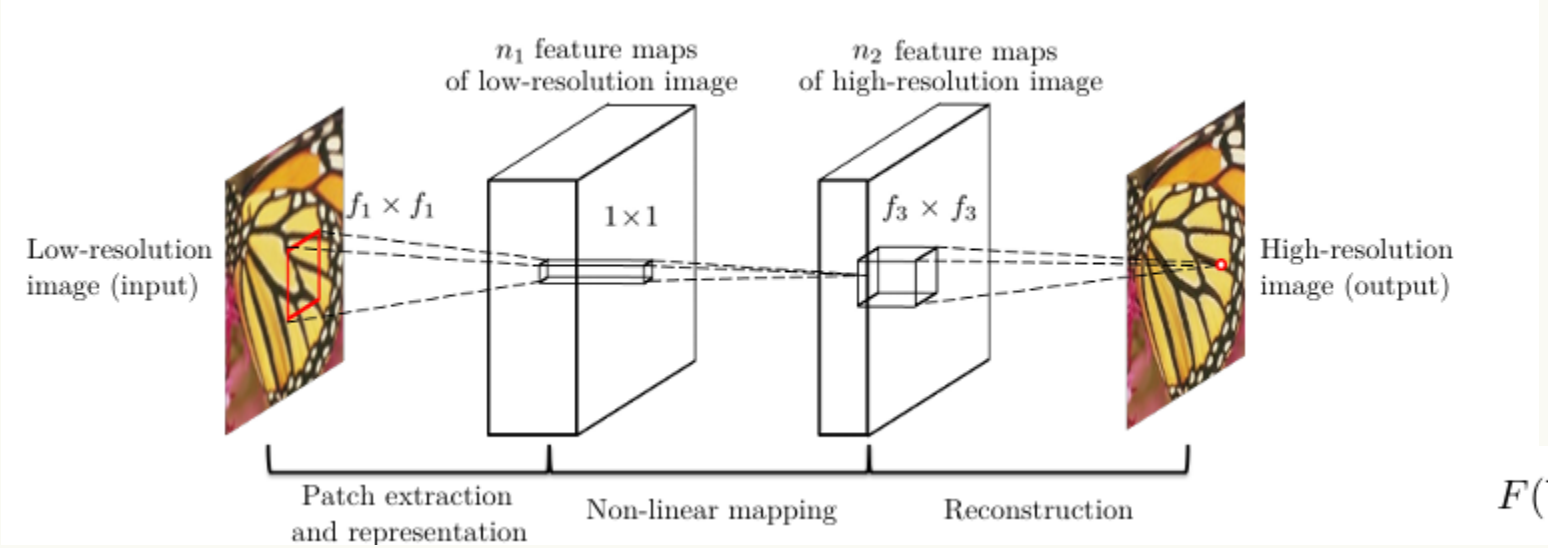

$$F(\mathbf{Y}) = W_3 * F_2(\mathbf{Y}) + B_3.$$

- 3층: 최종적으로 고해상도 이미지를 만들어낸다(재구성, 커널 크기 5x5, 필터 수 1개)

- 마지막 conv는 앞에서 정리된 특징을 바탕으로 주변 픽셀 정보를 함께 고려해 최종 고해상도 이미지를 생성
- 실제로 복원 결과를 출력하는 단계

01 | SRCNN

핵심 구조

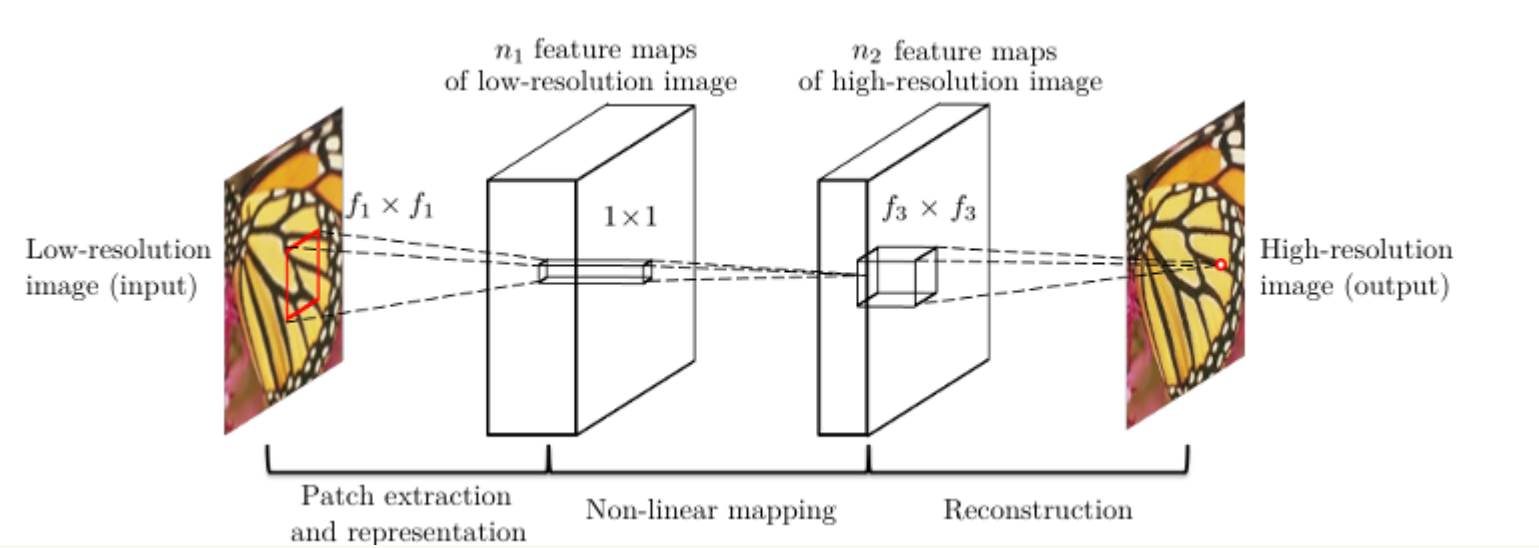

1. 이미지의 중요 특징 찾기
2. 그 특징을 복원에 유리하게 가공
3. 최종 고해상도 이미지 생성

전통적인 sparser-coding 기반 SR의 patch extraction, non-linear mapping, reconstruction 과정을 각각 convolution layer에 대응
→ SISR CNN의 모델의 연구 출발점

02 | VDSR – 심층 리뷰

간단 설명

- VDSR: 초해상도(SISR)에 처음으로 깊은 CNN을 본격적으로 성공 적용한 모델

1. 20-layer deep CNN
2. Residual learning
3. High learning rate + adjustable gradient clipping
4. Single model for multi-scale SR

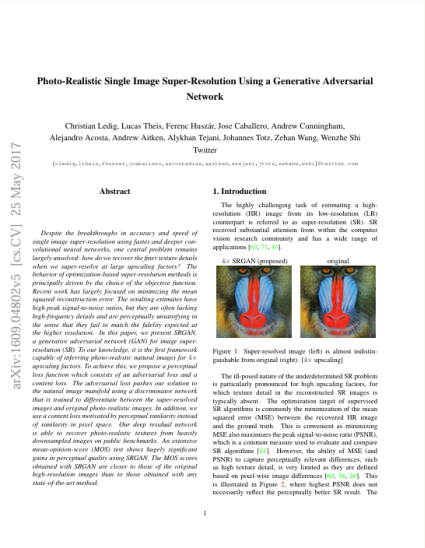

arXiv:1609.04802v5 [cs.CV] 25 May 2017

Photo-Realistic Single Image Super-Resolution Using a Generative Adversarial Network

Christian Ledig, Lucas Theis, Ferenc Huszár, Jose Caballero, Andrew Cunningham, Alejandro Acosta, Andrew Aitken, Alykhan Tejani, Johannes Totz, Zehan Wang, Wenzhe Shi
Twitter
[cledig,ltheis,fhuszar,jcaballero,acunningham,aacosta,aaitken,atejani,jtotz,zehanw,wenzhes]@twitter.com

Abstract

Despite the breakthroughs in accuracy and speed of single image super-resolution using faster and deeper convolutional neural networks, one central problem remains largely unsolved: how do we recover the finer texture details when we super-resolve at large upscaling factors? The behavior of optimization-based super-resolution methods is principally driven by the choice of the objective function. Recent work has largely focused on minimizing the mean squared reconstruction error. The resulting estimates have high peak signal-to-noise ratios, but they are often lacking high-frequency details and are perceptually unsatisfying in the sense that they fail to match the fidelity expected at the higher resolution. In this paper, we present SRGAN, a generative adversarial network (GAN) for image super-resolution (SR). To our knowledge, it is the first framework capable of inferring photo-realistic natural images for 4× upscaling factors. To achieve this, we propose a perceptual loss function which consists of an adversarial loss and a content loss. The adversarial loss pushes our solution to the natural image manifold using a discriminator network that is trained to differentiate between the super-resolved images and original photo-realistic images. In addition, we use a content loss motivated by perceptual similarity instead of similarity in pixel space. Our deep residual network is able to recover photo-realistic textures from heavily downsampled images on public benchmarks. An extensive mean-opinion-score (MOS) test shows hugely significant gains in perceptual quality using SRGAN. The MOS scores obtained with SRGAN are closer to those of the original high-resolution images than to those obtained with any state-of-the-art method.

1. Introduction

The highly challenging task of estimating a high-resolution (HR) image from its low-resolution (LR) counterpart is referred to as super-resolution (SR). SR received substantial attention from within the computer vision research community and has a wide range of applications [53, 73, 43].

4× SRGAN (proposed) original

Figure 1: Super-resolved image (left) is almost indistinguishable from original (right). [4× upscaling]

The ill-posed nature of the underdetermined SR problem is particularly pronounced for high upscaling factors, for which texture detail in the reconstructed SR images is typically absent. The optimization target of supervised SR algorithms is commonly the minimization of the mean squared error (MSE) between the recovered HR image and the ground truth. This is convenient as minimizing MSE also maximizes the peak signal-to-noise ratio (PSNR), which is a common measure used to evaluate and compare SR algorithms [61]. However, the ability of MSE (and PSNR) to capture perceptually relevant differences, such as high texture detail, is very limited as they are defined based on pixel-wise image differences [69, 58, 20]. This is illustrated in Figure 2, where highest PSNR does not necessarily reflect the perceptually better SR result. The

1

이 4가지를 결합하여, 기존 SRCNN보다 더 정확하고 더 빠르게 수렴하는 구조

02 | VDSR – 심층 리뷰

개요

- VDSR 이전에 대표적인 딥러닝 SR 모델은 SRCNN
- SRCNN은 CNN을 초해상도에 성공적으로 적용했다는 점에서 의미가 큼
  - 한계가 분명함
    - 문맥 부족: 얕은 네트워크는 넓은 영역 정보를 보기 어렵다
    - 수렴 속도 문제: 깊게 만들면 성능이 좋아질 가능성은 있지만 학습이 너무 느리고 불안정하다
    - 스케일별 모델 분리 문제: x2, x3, x4 확대마다 별도 모델을 두는 것은 비효율적이다

- 즉, VDSR은 단순한 “성능 개선 모델”이 아니라, SRCNN의 구조적 한계를 정면으로 해결하려는 모델

02 | VDSR – 심층 리뷰

핵심 아이디어

더 깊게 쌓는다: 20개 weight layer

- VDSR은 최종적으로 20개의 weight layer를 사용
  - 모든 중간층은 거의 동일한 형태로 구성, 3x3 conv filter를 반복적으로 사용
  - 첫 층과 마지막 층을 제외한 중간층에 64개의 3x3x64 필터를 사용

- 입력은 원하는 크기로 bicubic interpolation된 LR이미지로, 네트워크는 그 위에 추가될 세부 디테일(residual)을 예측

- 큰 필터를 한 번 쓰는 대신, 작은 필터를 여러 번 쌓아 더 넓은 수용영역을 확보
  - 깊이D인 네트워크의 receptive field가 (2D+1) x (2D+1)크기로 설명
  - 깊이가 20이라면 약 41x41수준의 문맥 정보를 볼 수 있음

- **초해상도는 주변 맥락을 많이 봐야 잘 복원 → 깊은 네트워크가 필요하다.**

02 | VDSR – 심층 리뷰

핵심 아이디어

이미지를 통째로 예측하지 않고 “차이”만 학습한다

- 핵심 포인트는 Residual Learning
  - 입력 LR이미지와 정답 HR이미지는 완전히 다른 이미지가 아니라, 상당 부분이 이미 유사 → 실제로 초해상도 문제에서 새로 복원해야 하는 것은 전체 이미지가 아닌 경계선, 텍스처, 윤곽 같은 고주파 디테일.
    - HR – LR의 차이(residual)만 학습하도록 설계
- 입력 이미지 자체는 이미 저주파 정보(밝기, 큰 구조, 부드러운 영역)을 많이 소유
- 네트워크는 굳이 저주파 정보를 포함한 전체 이미지를 만들 필요가 없음
- 대신 “부족한(고주파) 디테일만 보정” 하면 된다.

1. 학습 대상이 더 간단.
2. 깊은 네트워크의 수렴이 훨씬 빨라짐.

02 | VDSR – 심층 리뷰

핵심 아이디어

학습률을 매우 크게 쓰고, gradient clipping으로 제어한다

- 깊은 CNN을 제대로 학습시키려면 보통 시간이 오래 걸립니다.
- SRCNN 보다 10^4배 높은 초기 learning rate를 사용 → 수렴 시간 해결
- Gradient explosion문제 발생 → adjustable gradient clipping 사용
  - Gradient clipping: $g = \max(\min(g, \theta), -\theta)$

•gradient = 12
•clipping 범위 = [-5, 5] → 실제 업데이트 에는 5만 사용

- VDSR은 "깊은 모델이 안 되는 것 처럼 보였던 이유"를 구조 문제가 아닌, 학습 전략 문제로 봄
- 논문은 실제로 20-layer 네트워크를 약 4시간 안에 학습할 수 있었고, 반면 3-layer SRCNN은 수 일이 걸린다고 언급

- 깊은 SR 모델이 성능이 안나오는 게 아니라, 제대로 학습을 못 시켰던 것이다.

02 | VDSR – 심층 리뷰

핵심 아이디어

하나의 네트워크로 여러 스케일을 처리한다

- 기존에는 x2, x3, x4 확대 마다 별도의 모델을 두는 경우가 많았음
- VDSR은 sigle model for multi-scale SR을 제안
  - 여러 scale factor을 섞어서 학습시켜 한 모델이 여러 배율을 처리하게 만든 것

- 단일 스케일로 학습한 모델은 다른 스케일에 일반화가 잘 안된다.
- 하지만 x2, x3, x4를 함께 학습한 multi-scale 모델은 각 스케일에서 single-scale 모델과 비슷하거나, 큰 배율에서는 더 좋은 성능도 보인다.

- 실용적인 제안, 모델 저장/배포/사용 측면에서 비용을 줄임

02 | VDSR – 심층 리뷰

구조 간단 설명

1. 저해상도 이미지를 먼저 bicubic interpolation으로 원하는 크기까지 키운다
2. 그 이미지를 20층짜리 CNN에 넣는다
3. CNN은 “완성 이미지”가 아닌 복원해야 할 디테일(residual)만 예측한다
4. 마지막에 업샘플링 된 입력 이미지 + 예측 residual = 최종 고해상도 이미지로 복원한다

먼저 대충 키우고, Deep CNN
이 디테일을 복구하는 방식

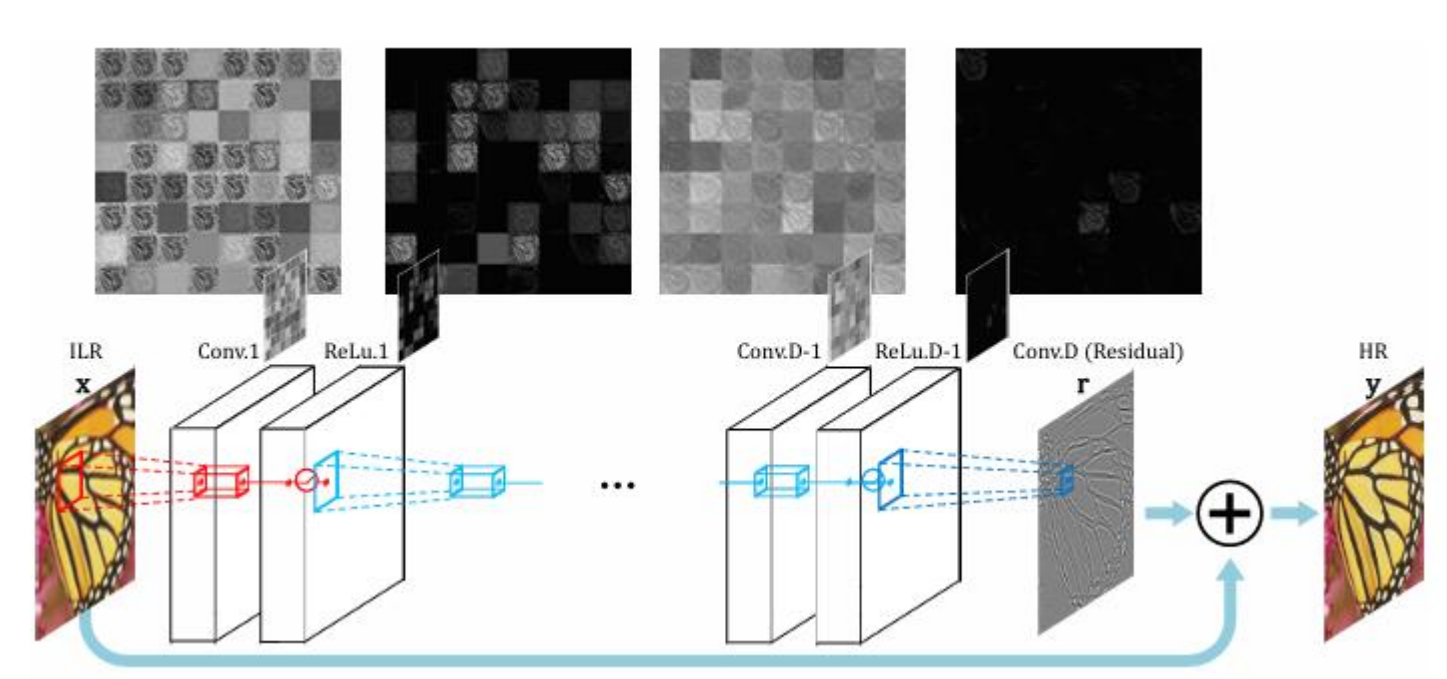

02 | VDSR – 심층 리뷰

성능 결과

Residual vs Non-Residual

Epoch, learning rate → PNSR(복원 성능 수치)

Epoch	10	20	40	80
Residual	36.90	36.64	37.12	37.05
Non-Residual	27.42	19.59	31.38	35.66
Difference	9.48	17.05	5.74	1.39

(a) Initial learning rate 0.1

Epoch	10	20	40	80
Residual	36.74	36.87	36.91	36.93
Non-Residual	30.33	33.59	36.26	36.42
Difference	6.41	3.28	0.65	0.52

(b) Initial learning rate 0.01

Epoch	10	20	40	80
Residual	36.31	36.46	36.52	36.52
Non-Residual	33.97	35.08	36.11	36.11
Difference	2.35	1.38	0.42	0.40

(c) Initial learning rate 0.001

02 | VDSR – 심층 리뷰

성능 결과

깊이, 스케일, 성능 비교

PNSR(복원 성능 수치)

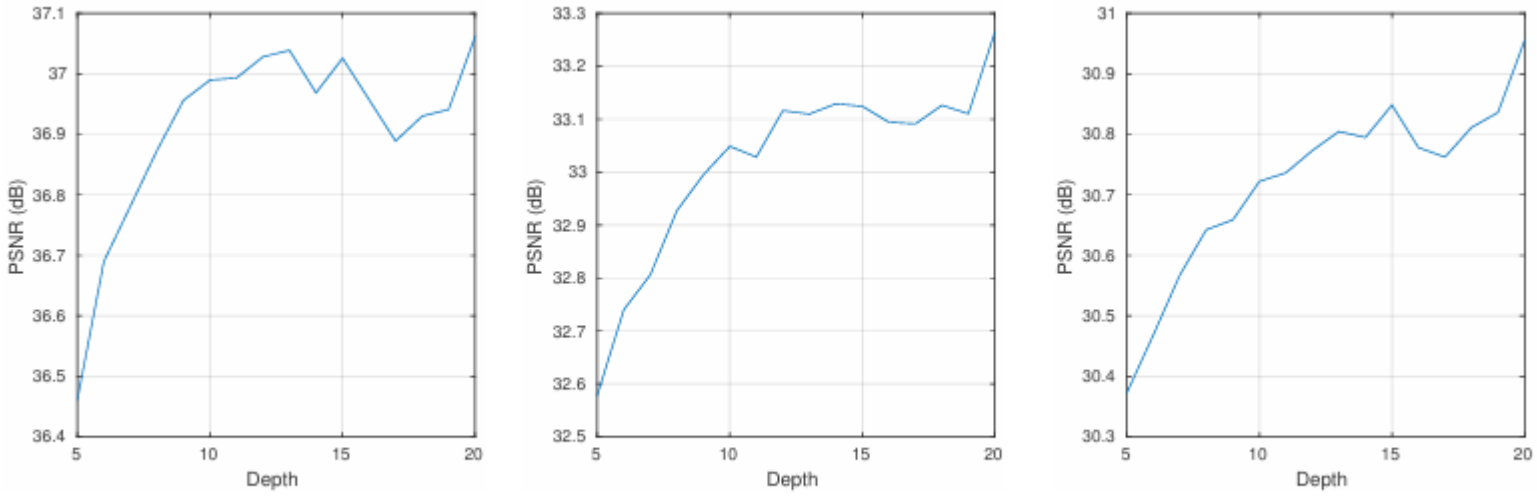

(a) Test Scale Factor 2 (b) Test Scale Factor 3 (c) Test Scale Factor 4

Depth 증가 → receptive field(한 출력값이 입력이미지에서 어느 범위를 봤는지) 증가 → PSNR 증가

능 결과

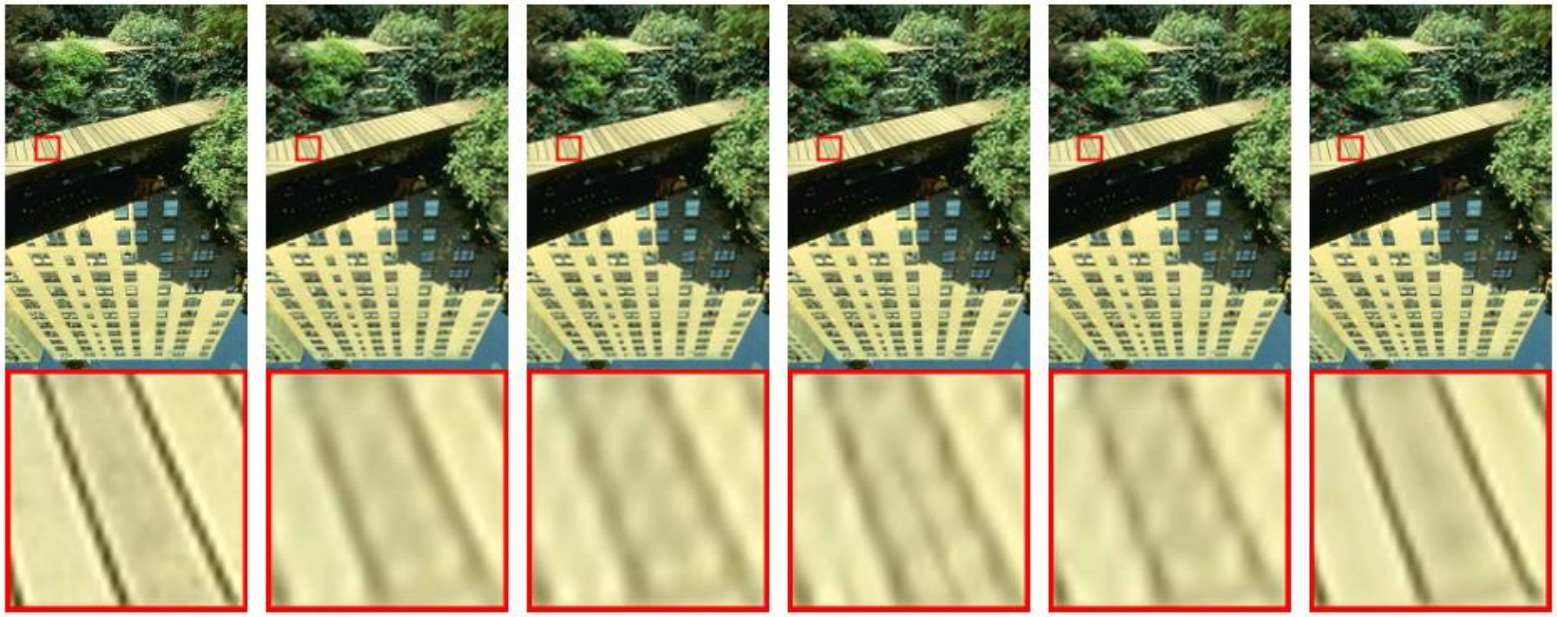

Ground Truth (PSNR, SSIM) | A+ [22] (22.92, 0.7379) | RFL [18] (22.90, 0.7332) | SelfEx [11] (23.00, 0.7439) | SRCNN [5] (23.15, 0.7487) | VDSR (Ours) (23.50, 0.7777)

PNSR(복원 성능 수치)
SSIM(구조적 유사도)

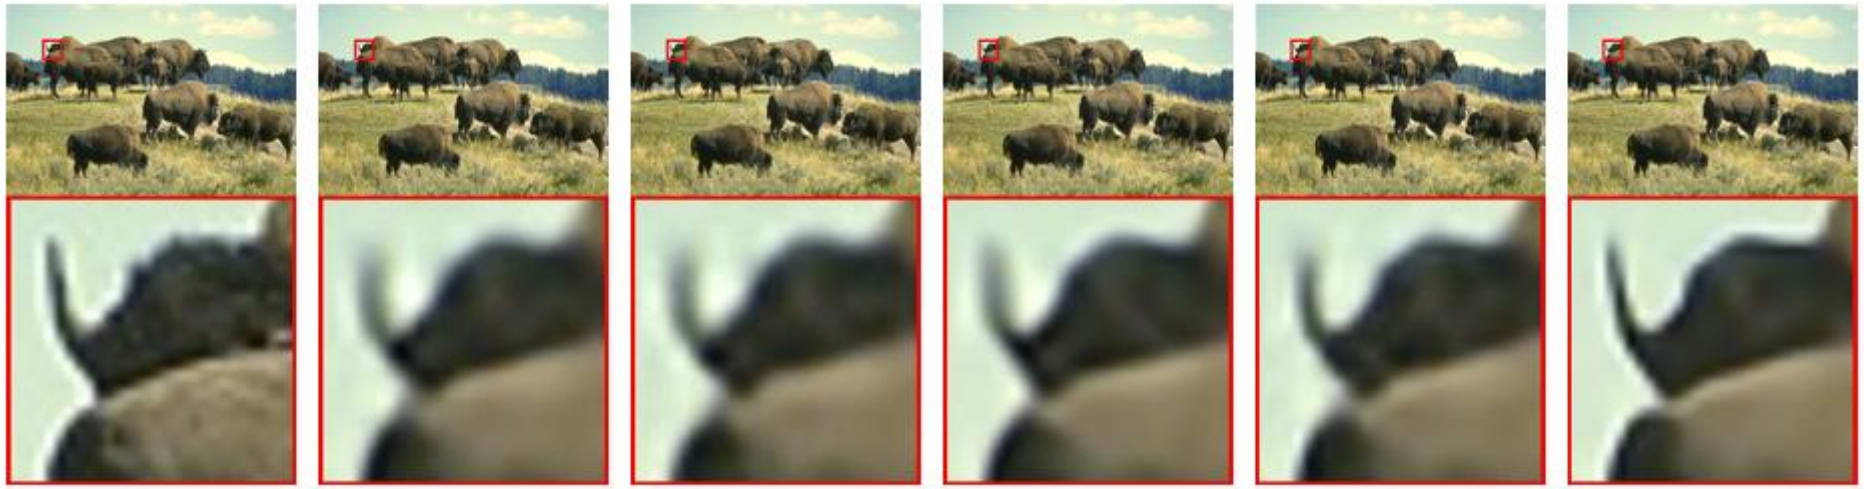

Ground Truth (PSNR, SSIM) | A+ [22] (27.08, 0.7514) | RFL [18] (27.08, 0.7508) | SelfEx [11] (27.02, 0.7513) | SRCNN [5] (27.16, 0.7545) | VDSR (Ours) (27.32, 0.7606)

입력:
학습 데이터셋 D = {(LR, HR)}
확대 배율 집합 S = {×2, ×3, ×4} 또는 단일 배율
출력:
학습된 VDSR 모델

[초기 설정]
1. VDSR 네트워크를 구성한다.
- 총 20개의 weight layer 사용
- 모든 합성곱 필터 크기는 3×3
- 첫 층: 입력 이미지 → 64채널 특징맵
- 중간 층(2~19층): 64채널 → 64채널, ReLU 적용
- 마지막 층: 64채널 → 1채널 residual(차이) image 출력
- 각 층에서 zero-padding을 적용하여 입력과 출력 크기를 동일하게 유지(conv로 인해 작아진 이미지를 입력과 출력의 크기를 같게 유지)

2. 네트워크 가중치를 초기화한다.
- ReLU에 적합한 He initialization(적절한 시작) 사용

3. 학습 하이퍼파라미터를 설정한다.
- Optimizer: mini-batch gradient descent + backpropagation
- batch size = 64
- momentum = 0.9(안정적 수렴)
- weight decay = 0.0001(가중치 억제 정규화)
- 초기 learning rate $\gamma = 0.1$
- learning rate는 20 epoch마다 10배씩 감소(step decay)
- 전체 학습 epoch = 80
- adjustable gradient clipping(학습률 - 가중치 억제) 사용
  gradient clipping 범위 = $[-\theta/\gamma, \theta/\gamma]$

[학습 반복]
4. epoch = 1 부터 80까지 반복한다.

5. 현재 epoch에 따라 learning rate를 갱신한다.(step decay – 초반에 빠른 방향성 찾기, 후반엔 세밀하게 다듬기)
- epoch 1~20 : γ = 0.1
- epoch 21~40 : γ = 0.01
- epoch 41~60 : γ = 0.001
- epoch 61~80 : γ = 0.0001

6. 학습 데이터셋에서 mini-batch를 구성한다.
- 한 batch는 64개의 sub-image(패치)로 구성

7. batch 안의 각 저해상도 이미지 LR에 대해 다음을 수행한다.

7-1. LR 이미지를 bicubic interpolation으로 목표 크기까지 먼저 확대한다.
ILR = BicubicUpsample(LR)

7-2. 정답 residual image를 계산한다.
R_gt = HR - ILR

7-3. 확대된 이미지 ILR을 네트워크 입력으로 넣는다.
X = ILR

7-4. 첫 번째 합성곱 계층을 수행한다.(선, 모서리, 윤곽 – 기본적인 특징)
X = ReLU(Conv(X, 3×3, 64))

7-5. 중간 합성곱 계층을 반복한다. (receptive filed확대, 복잡한 특징 학습, 고주파 복원 능력 향상)
for i = 2 to 19:
X = ReLU(Conv(X, 3×3, 64))

7-6. 마지막 합성곱 계층으로 residual을 예측한다. (예측 residual image생성 – ILR에 더해줘야 될 차이 정보)
R_pred = Conv(X, 3×3, 1)

7-7. 최종 복원 이미지를 계산한다. (복원 이미지 생성)
SR = ILR + R_pred

7-8. 손실 함수를 계산한다.
$Loss = ||SR - HR||^2$
$= ||R_pred - R_gt||^2$
(Euclidean loss / MSE 기반)

8. batch 전체에 대해 손실을 평균낸다.

9. 역전파(backpropagation)를 수행하여 각 가중치의 gradient를 계산한다.

10. exploding gradient를 막기 위해 gradient clipping을 적용한다.
- 각 gradient를 $[-\theta/\gamma, \theta/\gamma]$ 범위로 제한한다.

11. momentum과 weight decay를 반영하여 가중치를 업데이트한다.

12. 모든 batch에 대해 반복한 뒤 다음 epoch로 진행한다.

13. 80 epoch 학습이 끝나면 최종 VDSR 모델을 반환한다.

Bicubic으로 먼저 키운 저해상도 이미지에서, 정답과의 차이만 깊은 CNN으로 학습하고,
큰 learning rate와 gradient clipping을 이용해 빠르고 안정적으로 학습하는 과정

02 | VDSR – 심층 리뷰

공헌

1. SR에서 깊은 네트워크가 유효하다는 것을 증명
   - SRCNN 이후에는 깊게 쌓아도 효과가 없다는 인식이 많았음.
   - VDSR은 학습 전략을 바꾸면 깊은 모델이 훨씬 잘 된다는 점을 증명
2. Residual learning을 SR에 강하게 정착
   - 이후 SRResNet, EDSR, RSGAN 같은 후속 모델들은 모두 어떤 형태로든 저주파를 우회 시키고 고주파 복원에 집중하는 철학을 계승. VDSR은 초반 핵심모델
3. multi-scale single model이라는 실용적 방향을 제시
   - 배율마다 따로 모델을 두는 불편함을 줄였고, SR을 보다 실사용 관점에서 다루려는 시도를 보임.

02 | VDSR – 심층 리뷰

한계

PNSR 중심이라 시각적 사실감의 한계
VDSR은 MSE 기반 복원 계열, PNSR/SSIM 개선

해당 계열의 전형적인 특징은 수치상 좋지만, 시각적으로는 다소 부드럽게 보수적인 결과가 생성.

다음 논문에서 해당 한계 극복

02 | VDSR – 심층 리뷰

한계

VDSR은 20층으로 깊지만, 후속 모델들과 비교하면 구조는 꽤 단순함

Dense connection, channel attention, perceptual prior없음
Transformer 계열 구조 아님

당시엔 “깊다”라는 점에서 혁신적이였음.
후속 모델(EDSR, SRGAN)들의 출발점

01 | SRGAN

GAN

- GAN : 생성자(Genator)와 판별자(Discriminator)가 서로 경쟁하면서 학습하는 구조
  - 생성자: 진짜처럼 보이는 이미지를 만들려고 함
  - 판별자: 들어온 이미지가 진짜인지 가짜인지 구분하려고 함
- **경쟁 과정이 반복되면서 생성자는 점점 자연스럽고 사실적인 결과를 만들게 됨**

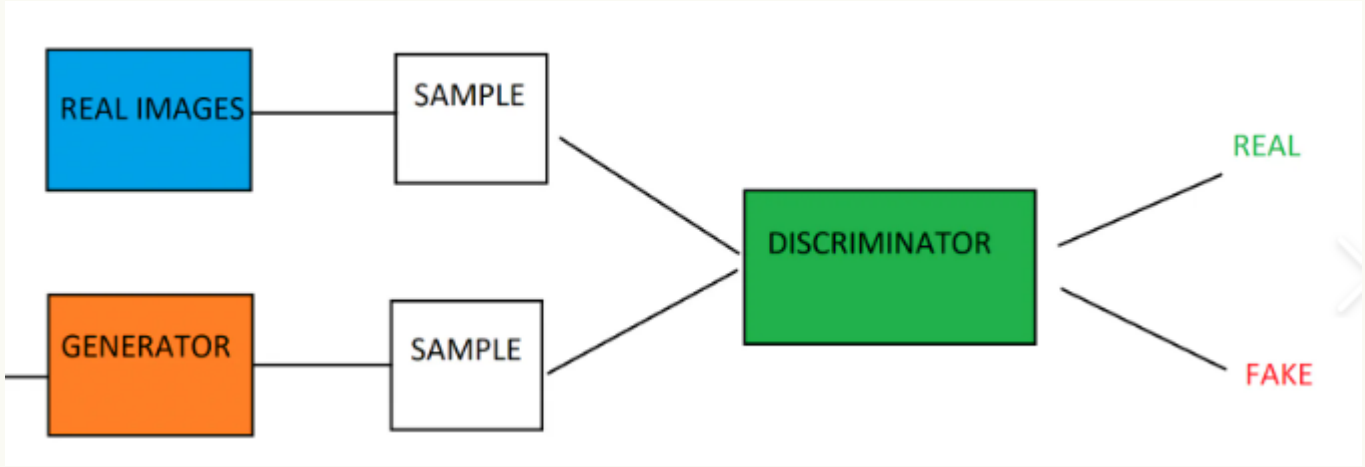

01 | SRGAN

GAN의 필요

- 이미지 복원 문제에서 단순 오차 픽셀만 줄이기 → 전체 구조, loss 는 맞더라도 결과가 지나치게 부드럽고 평균적인 이미지가 생성

- **GAN : "정답과 얼마나 똑같은가" , "실제 사진 처럼 보이는가"를 학습에 반영할 수 있기 때문에, 질감과 고주파 디테일을 더 자연스럽게 복원하는 데 유리**

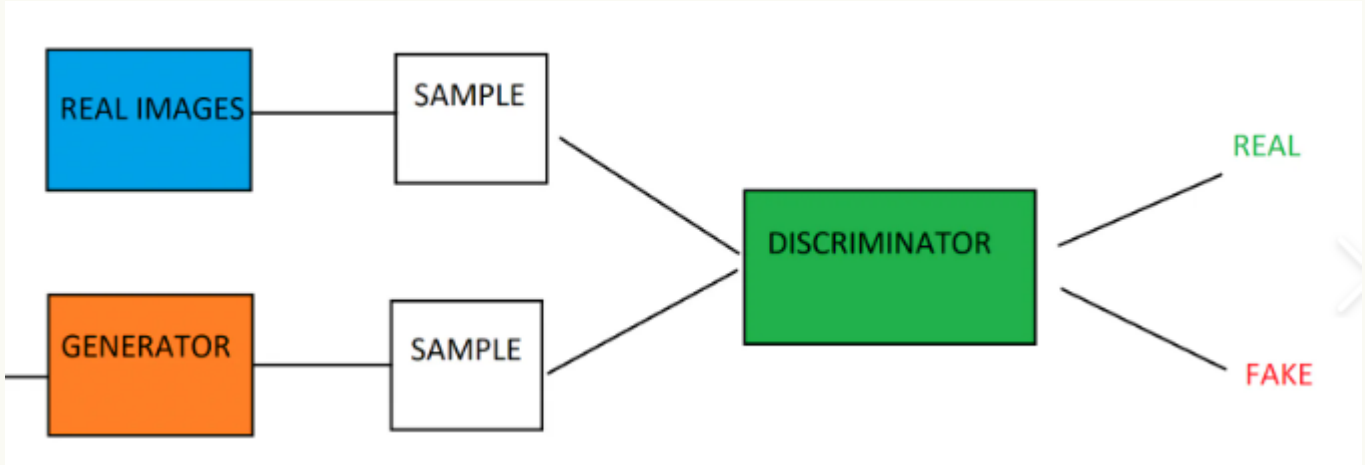

01 | SRGAN 간단 설명

- SRGAN: 기존 MSE 중심 복원의 한계를 넘어, 텍스처와 시각적 사실감을 더 잘 복원하기 위해 GAN 구조를 도입한 초해상도 모델(2017)

- 핵심 키워드: SISR, GAN, perceptual loss, texture restoration, photo-realistic SR

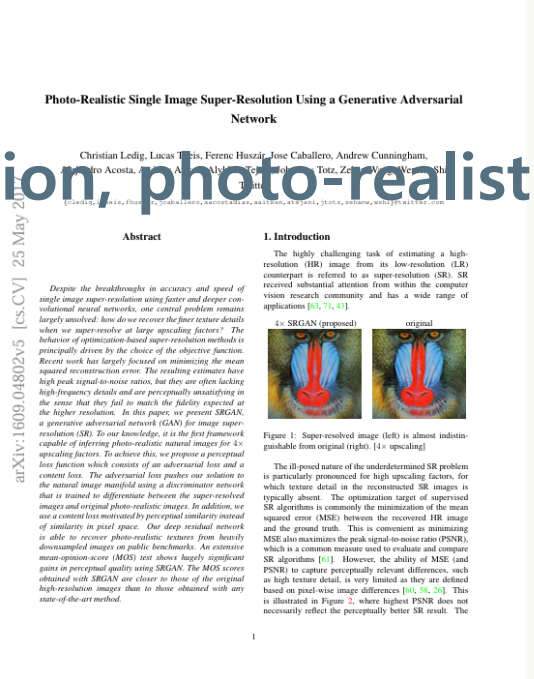

Photo-Realistic Single Image Super-Resolution Using a Generative Adversarial Network

Christian Ledig, Lucas Theis, Ferenc Huszár, Jose Caballero, Andrew Cunningham, Alejandro Acosta, Andrew Aitken, Alykhan Tejani, Johannes Totz, Zehan Wang, Wenzhe Shi
Twitter

Abstract

Despite the breakthroughs in accuracy and speed of single image super-resolution using faster and deeper convolutional neural networks, one central problem remains largely unsolved: how do we recover the finer texture details when we super-resolve at large upscaling factors? The behavior of optimization-based super-resolution methods is principally driven by the choice of the objective function. Recent work has largely focused on minimizing the mean squared reconstruction error. The resulting estimates have high peak signal-to-noise ratios, but they are often lacking high-frequency details and are perceptually unsatisfying in the sense that they fail to match the fidelity expected at the higher resolution. In this paper, we present SRGAN, a generative adversarial network (GAN) for image super-resolution (SR). To our knowledge, it is the first framework capable of inferring photo-realistic natural images for 4× upscaling factors. To achieve this, we propose a perceptual loss function which consists of an adversarial loss and a content loss. The adversarial loss pushes our solution to the natural image manifold using a discriminator network that is trained to differentiate between the super-resolved images and original photo-realistic images. In addition, we use a content loss motivated by perceptual similarity instead of similarity in pixel space. Our deep residual network is able to recover photo-realistic textures from heavily downsampled images on public benchmarks. An extensive mean-opinion-score (MOS) test shows hugely significant gains in perceptual quality using SRGAN. The MOS scores obtained with SRGAN are closer to those of the original high-resolution images than to those obtained with any state-of-the-art method.

1. Introduction

The highly challenging task of estimating a high-resolution (HR) image from its low-resolution (LR) counterpart is referred to as super-resolution (SR). SR received substantial attention from within the computer vision research community and has a wide range of applications [63, 71, 43].

4× SRGAN (proposed) original

Figure 1: Super-resolved image (left) is almost indistinguishable from original (right). [4× upscaling]

The ill-posed nature of the underdetermined SR problem is particularly pronounced for high upscaling factors, for which texture detail in the reconstructed SR images is typically absent. The optimization target of supervised SR algorithms is commonly the minimization of the mean squared error (MSE) between the recovered HR image and the ground truth. This is convenient as minimizing MSE also maximizes the peak signal-to-noise ratio (PSNR), which is a common measure used to evaluate and compare SR algorithms [61]. However, the ability of MSE (and PSNR) to capture perceptually relevant differences, such as high texture detail, is very limited as they are defined based on pixel-wise image differences [60, 58, 26]. This is illustrated in Figure 2, where highest PSNR does not necessarily reflect the perceptually better SR result. The

arXiv:1609.04802v5 [cs.CV] 25 May 2

1

01 | SRGAN 개요, 제안 배경

- 기존 MSE 기반 초해상도 복원이 가지던 흐릿, 부드러운 결과를 개선하기 위한 모델

- 기존 MSE 기반 → 픽셀 단위 차이를 줄이는 학습
  - PNSR 같은 정량 지표는 향상
  - 디테일이 부족하고 질감이 뭉개지는 한계

- GAN 도입
- Percptual Loss(사람이 보기 좋은 방향으로 비교하는 손실) 도입 MSE(픽셀 값 손실)

→ 수치적으로 맞는 이미지가 아닌 시각적으로 더 realstic한 고해상도 이미지 생성

01 | SRGAN

전체 구조

- Biscubic : LR이미지 확대
- Generator: Biscubic 확대 이미지를 받아 고해상도 이미지를 생성
- Discriminator: 해당 이미지가 진짜 고해상도 이미지인지 생성된 가짜 이미지인지를 판별

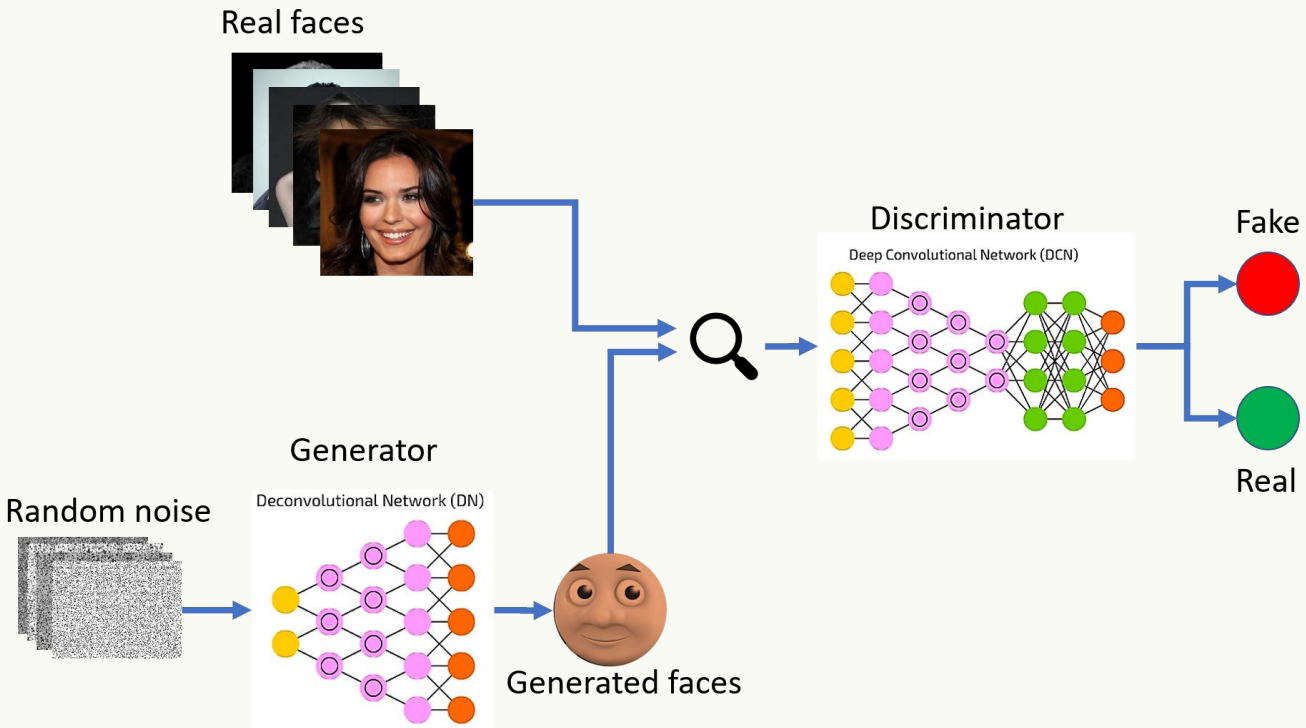

01 | SRGAN

전체 구조

- Generator: SRResNet 기반의 residual network를 사용. SRGAN은 완전히 새로운 복원기라기보다 SRResNet계열의 깊은 residual 구조를 생성기로 채택하고, 여기에 GAN 학습을 결합한 형태.

- Residual network: 입력 전체를 처음부터 다시 만드는 것이 아니라, 원본과 입력의 차이(residual)만 학습한다
  - 이미 있는 저주파 정보는 최대한 그대로 두고, 부족한 고주파/세부 정보만 보정한다.

- Generator는 이미지 복원 생성기 : Residual Block 16개 → Conv, BatchNorm…

01 | SRGAN

전체 구조

- Discrimitator: 생성 이미지와 원본 이미지를 사람이 보듯이 나란히 놓고 세부를 직접 설명하는 모델이 아닌, 기본적인 입력 이미지가 real인지 fake 인지 판별하는 분류기. 실제로는 확률 점수에 가까운 값을 출력.
- Generator는 이 판별 신호를 이용해 더 자연스럽고 사실적인 질감을 만들도록 학습

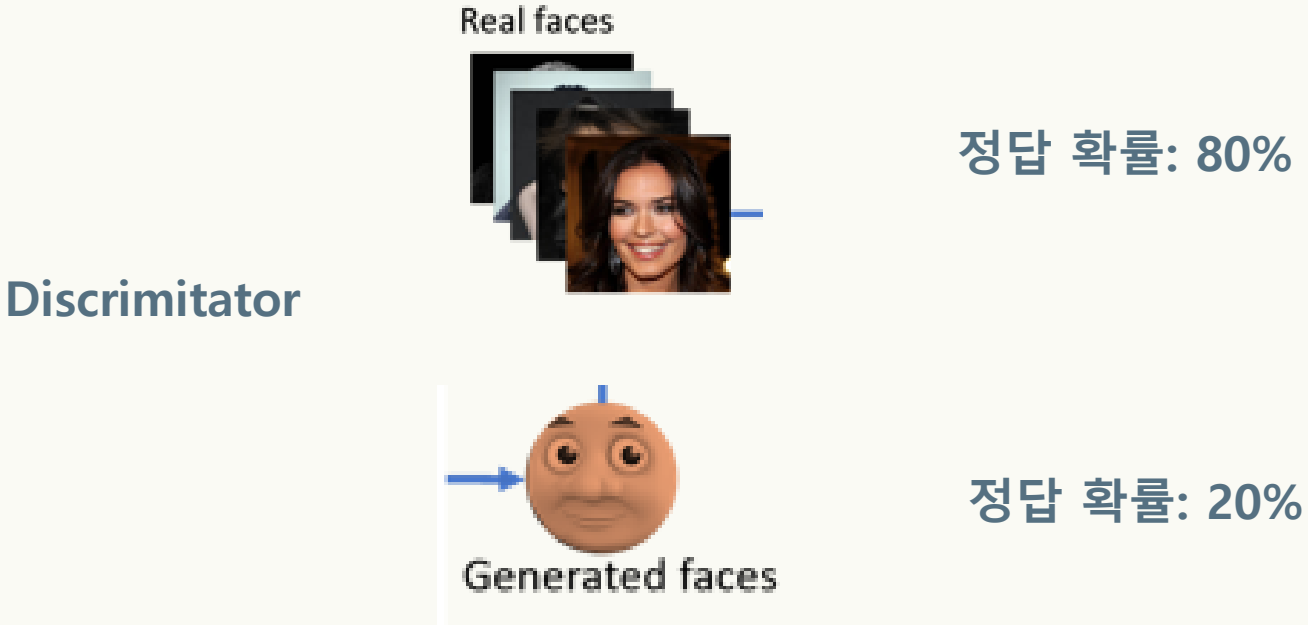

01 | SRGAN

손실 함수

- 손실을 지각 품질 중심으로 설계
  - Content loss, Adversarial loss

손실 항목	비교 대상	의미
Content loss	생성 이미지 ↔ 원본 HR 이미지	원본과 내용적으로 얼마나 비슷한지 반영한다. SRGAN에서는 주로 VGG feature map 기반 비교를 사용한다.
Adversarial loss	생성 이미지 ↔ Discriminator의 판별 결과	생성 이미지가 Discriminator에게 진짜처럼 보이도록 학습시킨다. 원본과 직접 픽셀 비교를 하는 손실은 아니다.

01 | SRGAN

핵심 구조

1. 저해상도 이미지가 Generaotr에 입력된다.
2. Generator가 고해상도 이미지를 생성한다.
3. 생성 이미지와 원본 HR이미지를 이용해 content loss를 계산한다.
4. 생성 이미지와 원본 HR이미지를 각각 Discriminator에 넣고 real/fake 판별 수행.
5. Generator는 원본과 내용이 비슷해야 하고, 동시에 Discriminator를 속일 만큼 진짜처럼 보여야 하므로 두 방향의 신호를 함께 반영해 학습된다.

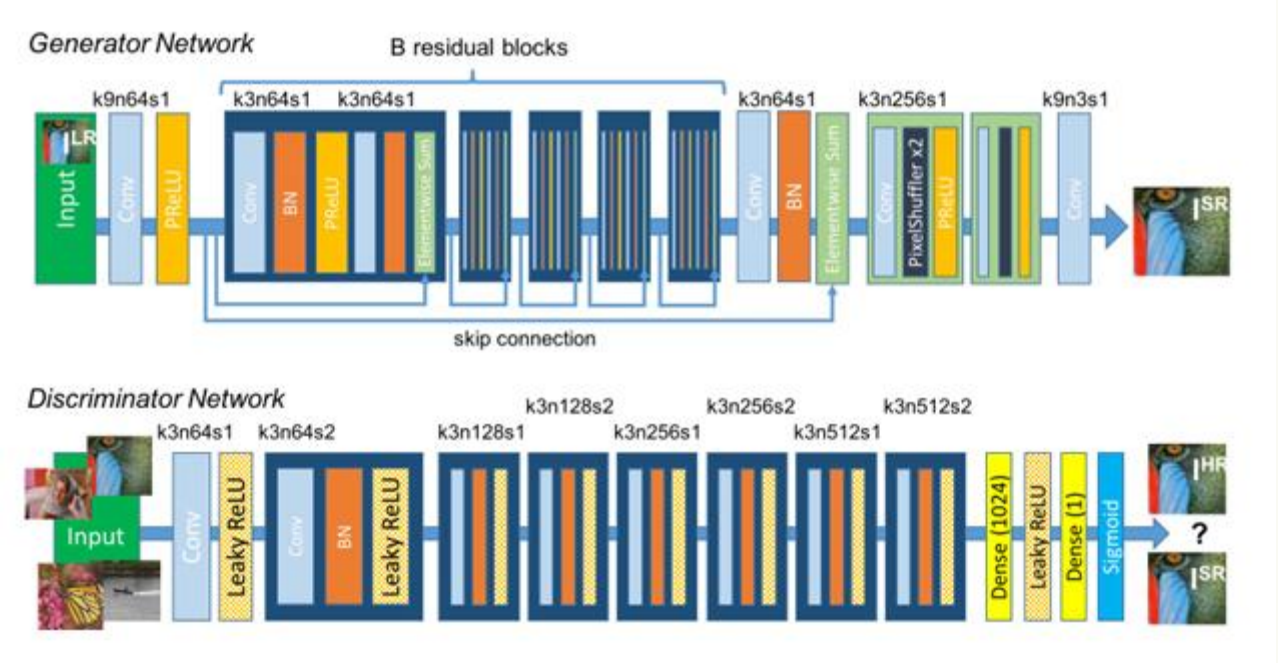

01 | 논문들의 한계

주관적인 해석

실제 LR이미지와 학습용 LR이미지의 차이

학습용 LR: 좋은 원본 이미지를 그냥 수학적으로 작게 줄인 이미지
해당 논문들은 HR이미지를 bicubic downsampling을 통해 저화도로 전환하였음.
즉, 인위적으로 저해상도 이미지를 만들었음

실제 LR: 화질 자체가 여러 방식으로 망가진 이미지
카메라 흔들림, 초점 불량, 센서 노이즈, 압축 손상, 조명문제

모델은 학습할 때 이런식으로 손상된 LR이면, HR은 이렇게 복원하면 되겠구나
실제 입력은 학습 때와 본 것 과 다르다.

시험 공부는 모의고사 유형으로 했는데, 실전 시험 문제 유형이 달라진 상황...

Super-Resolution
SRCNN, VDSR, SRGAN

감사합니다